

Błąd popularności w systemach rekomendujących

(Popularity Bias in recommender systems)

Mateusz Garncarczyk

Praca inżynierska

Promotor: dr hab. Piotr Wnuk-Lipiński

Uniwersytet Wrocławski
Wydział Matematyki i Informatyki
Instytut Informatyki

11 czerwca 2026

Streszczenie

Systemy rekomendujące borykają się z wieloma problemami, a jednym z najważniejszych jest błąd popularności (ang. *Popularity Bias*), polegający na faworyzowaniu przedmiotów popularnych kosztem elementów niszowych. Zjawisko to prowadzi do zniekształcenia wyników rekomendacji, ogranicza widoczność długiego ogona i utrudnia modelowi uczenie się bardziej subtelnych preferencji użytkowników. W niniejszej pracy analizujemy ten problem w kontekście grafowych systemów rekomendujących opartych na architekturze *LightGCN*.

Celem pracy było zbadanie, czy możliwe jest łagodzenie *Popularity Bias* poprzez ingerencję w sam proces uczenia modelu. W tym celu zaproponowaliśmy i przetestowaliśmy metody należące do kategorii *in-processing*, oparte z jednej strony na modyfikacji funkcji straty *BPR*, a z drugiej na zmianie struktury grafu podczas treningu. Badane podejścia obejmowały między innymi *Smoothed BPR*, *Inverse Propensity Scoring*, autorski model *FastLightGCN*, próbkowanie inspirowane *PinSage'em*, a także mechanizmy *edge dropout*, *node dropout* oraz ich hybrydowe połączenia.

Uzyskane wyniki pokazują, że ograniczanie błędu popularności jest możliwe, jednak wymaga zachowania kompromisu pomiędzy poprawą wyników dla przedmiotów niszowych a utrzymaniem jakości globalnej rekomendacji. Najlepsze metody pozwalały osłabić dominację hitów i poprawić widoczność elementów długiego ogona bez całkowitego załamania metryk globalnych. Otrzymane rezultaty potwierdzają, że odpowiednio dobrana modyfikacja funkcji straty i struktury grafu może skutecznie wspierać bardziej zrównoważone uczenie tych modeli.

Recommendation systems face many challenges, and one of the most significant is *Popularity Bias*, which involves favouring popular items at the expense of niche ones. This phenomenon leads to a distortion of recommendation results, limits the visibility of the long tail, and hinders the model’s ability to learn more subtle user preferences. In this paper, we analyse this problem in the context of graph-based recommendation systems based on the *LightGCN* architecture.

The aim of the work was to investigate whether it is possible to mitigate *Popularity Bias* by intervening in the model’s learning process itself. To this end, we proposed and tested methods belonging to the *in-processing* category, based on the one hand on modifying the *BPR* loss function, and on the other on altering the graph structure during training. The approaches investigated included, amongst others, *Smoothed BPR*, *Inverse Propensity Scoring*, the proprietary *FastLightGCN* model, *PinSage*-inspired sampling, as well as *edge dropout*, *node dropout* mechanisms and their hybrid combinations.

The results show that reducing the *Popularity Bias* is possible, but requires a trade-off between improving results for niche items and maintaining the quality of the overall recommendation. The best methods allowed us to reduce the dominance of hits and improve the visibility of long-tail items without completely compromising global metrics. The results confirm that a carefully chosen modification of the loss function and graph structure can effectively support more balanced training of these models.

Spis treści

1. Wprowadzenie	7
2. LightGCN	11
3. Definicja problemu	13
3.1. Błąd danych	13
3.2. Błąd modelu	14
3.3. Znaczenie błędu popularności	14
4. Krótki przegląd literatury	17
5. Proponowane podejścia	19
5.1. Smoothed BPR	19
5.2. Inverse Propensity Scoring	20
5.3. FastLightGCN	21
5.3.1. Eksplozja sąsiedztwa i ograniczenia pełnej propagacji	21
5.3.2. Aproksymacja warstwy spłotowej metodą Monte Carlo	21
5.3.3. Wady oryginalnego modelu próbkowania	22
5.3.4. Modyfikacja estymatora w architekturze FastLightGCN	22
5.4. Błądzenie losowe PinSage'a i dropouty	25
6. Eksperymenty	27
6.1. Dane treningowe	27
6.2. Proces treningowy	28
6.3. Metryki	29

6.3.1. Metryki diagnostyczne	30
6.3.2. Metryki ewaluacyjne	31
6.4. Wyniki eksperymentów	32
6.4.1. Smoothed BPR	33
6.4.2. Inverse Propensity Scoring	37
6.4.3. FastLightGCN	38
6.4.4. Błądzenie losowe PinSage'a i dropouty	49
6.4.5. Połączone podejścia	58
6.5. Podsumowanie eksperymentów	64
7. Podsumowanie	67
8. Dodatek	69
Bibliografia	79

Rozdział 1.

Wprowadzenie

Systemy rekomendujące są obecnie częścią wielu stron i usług internetowych. Stanowią one podkategorię systemów filtrowania informacji, których zadaniem jest wspieranie użytkowników w procesie podejmowania decyzji. Ich główną funkcją jest przewidywanie preferencji na podstawie wcześniejszych zachowań oraz personalizowanie sugerowanych produktów, takich jak wydarzenia, rzeczy, usługi czy reklamy, dla konkretnego odbiorcy. Z perspektywy użytkownika celem takich systemów jest ograniczenie problemu nadmiaru informacji (ang. *information overload*) [10] i ułatwienie odnalezienia najbardziej trafnych ofert w bardzo dużym zbiorze dostępnych opcji. Z kolei z perspektywy podmiotu wdrażającego ich podstawowym zadaniem jest realizacja celów biznesowych, takich jak wzrost sprzedaży, zaangażowania oraz lojalności klientów.

Wyróżniamy wiele typów systemów rekomendujących, klasyfikowanych ze względu na ich architekturę oraz sposób przetwarzania danych. Do najważniejszych paradygmatów należą modele oparte na treści (ang. *content-based filtering*), na wiedzy (ang. *knowledge-based*), modele współpracującego filtrowania (ang. *collaborative filtering*, *CF*) oraz rozwiązania hybrydowe [1]. Szczególną uwagę badaczy od lat przyciąga *CF*, ponieważ pozwala wykrywać ukryte wzorce zachowań użytkowników i relacje pomiędzy nimi a przedmiotami. Klasyczne modele tego typu bazowały przede wszystkim na faktoryzacji macierzy (ang. *Matrix Factorization*), jednak rozwój uczenia głębokiego doprowadził do ich ewolucji w kierunku grafowych sieci neuronowych (ang. *Graph Neural Networks*, *GNN*).

Rosnąca popularność architektur grafowych nie jest przypadkowa. Dane występujące w systemach rekomendujących mają naturalną strukturę relacyjną: użytkownicy wchodzią w interakcje z przedmiotami, a zbiory takich interakcji można interpretować jako graf dwudzielny. Dzięki temu modele *GNN* potrafią wykorzystywać zarówno bezpośrednie, jak i wieloskładnikowe zależności kolaboratywne, propagując sygnał preferencji poprzez lokalne sąsiedztwo węzłów. W obszarze rekomendacji jednym z najbardziej znanych modeli tego typu jest *LightGCN* [4], który upraszcza klasyczne architektury grafowe, rezygnując z transformacji liniowych oraz nielinio-

wych funkcji aktywacji na rzecz samej agregacji sąsiedztwa. W niniejszej pracy model ten pełni rolę podstawowego punktu odniesienia dla dalszych analiz i proponowanych modyfikacji.

Skuteczność systemów rekomendujących w dużej mierze zależy jednak od charakterystyki zbieranych danych. Pozyskiwanie bezpośrednich ocen użytkowników (ang. *explicit feedback*) jest kosztowne i trudne do skalowania, dlatego w praktyce przemysłowej dominują dane ukryte (ang. *implicit feedback*), takie jak kliknięcia, historia zakupów czy czas spędzony na stronie. Sygnały tego typu są łatwiejsze do zebrania, lecz jednocześnie znacznie bardziej niejednoznaczne, ponieważ nie zawsze wierne odzwierciedlają rzeczywiste preferencje użytkownika. Interakcja może wynikać z przypadku, ciekawości, chwilowej ekspozycji lub z samego sposobu prezentacji treści przez interfejs systemu. W efekcie dane uczące są z natury zaszumione i obciążone [1].

Problem ten staje się szczególnie istotny w architekturach grafowych. W literaturze podkreśla się, że *GNN* osiągają bardzo dobre wyniki w wielu zastosowaniach, ale w rzeczywistych środowiskach uczone są na danych dalekich od ideału. Na ich skuteczność negatywnie wpływają między innymi niezbalansowanie rozkładu danych, obecność różnych form szumu, ograniczenia związane z prywatnością oraz trudności generalizacji poza rozkład treningowy (ang. *out of distribution, OOD*) [5]. W systemach rekomendujących szczególne znaczenie ma jednak, wspomniany wcześniej, szum strukturalny (ang. *Structure Noise*), ponieważ osadzenia propagowane są dalej, niezależnie od tego, czy odzwierciedlają one rzeczywiste preferencje, czy jedynie pozostałości procesu ekspozycji i zbierania danych.

Zjawisko *Structure Noise* oznacza obecność połączeń, które są mało informacyjne, przypadkowe lub wprowadzają do grafu błędny sygnał. W kontekście rekomendacji, część relacji użytkownik–przedmiot nie wynika z rzeczywistego zainteresowania, lecz z promowania określonych treści, ich lepszej widoczności albo z samej dominacji popularnych obiektów w interfejsie systemu. Modele grafowe budują reprezentacje na podstawie lokalnej topologii, zatem takie zaburzenia nie pozostają lokalne, lecz mogą być wzmacniane i propagowane w kolejnych warstwach agregacji. W rezultacie model uczy się nie tylko preferencji użytkowników, ale również strukturalnych deformacji obecnych w danych wejściowych.

Jednym z najważniejszych skutków tego procesu jest skrzywienie ku popularności (ang. *Popularity Bias*), polegające na systematycznym faworyzowaniu przedmiotów popularnych kosztem elementów należących do tzw. długiego ogona (ang. *long tail*). W praktyce oznacza to, że model chętniej rekomenduje obiekty często obserwowane i silnie osadzone w strukturze grafu, podczas gdy przedmioty rzadsze, mimo że mogą być trafne i wartościowe dla użytkownika, są stopniowo wypychane z list rekomendacyjnych. Problem ten ma znaczenie nie tylko z punktu widzenia jakości personalizacji, ale również różnorodności, reprezentatywności oraz sprawiedliwego traktowania mniej popularnych obiektów. Ze względu na centralną rolę tego

zjawiska w niniejszej pracy jego formalna definicja oraz szersze omówienie zostaną przedstawione w kolejnym rozdziale.

Celem pracy jest zbadanie, w jakim stopniu możliwe jest łagodzenie *Popularity Bias* bezpośrednio na etapie uczenia modelu grafowego. Przyjęta perspektywa badawcza koncentruje się na metodach z kategorii *in-processing*, a więc takich, które ingerują w sam proces optymalizacji, zamiast modyfikować dane przed treningiem albo przekształcać gotowe rankingi po jego zakończeniu. W pracy analizujemy dwa główne kierunki tego typu działań. Pierwszy z nich dotyczy modyfikacji funkcji straty *BPR* w celu zmiany charakteru sygnału uczącego dla przedmiotów popularnych i niszowych. Drugi obejmuje strukturalną regularyzację grafu poprzez techniki próbkowania (ang. *sampling*) i *dropout*, które mają ograniczać dominację gęstych obszarów topologii oraz osłabiać propagację szumu strukturalnego.

Istotnym elementem niniejszej pracy jest także sposób analizy badanego zjawiska. Ocena jakości metod nie ogranicza się wyłącznie do klasycznych metryk rankingowych liczonych globalnie. Wprowadzamy również podział przedmiotów na grupy popularności oraz stosujemy metryki diagnostyczne opisujące dynamikę osadzeń w trakcie treningu. Takie podejście pozwala obserwować *Popularity Bias* nie tylko jako efekt widoczny w końcowych rekomendacjach, ale również jako zjawisko ujawniające się w samej przestrzeni ukrytej procesu uczenia reprezentacji. Dzięki temu możliwa staje się głębsza analiza wpływu badanych metod na zachowanie modeli grafowych.

Rozdział 2.

LightGCN

LightGCN [4] to model *CF* opierający się na uproszczonych grafowych sieciach konwolucyjnych (ang. *Graph Convolutional Networks, GCN*). W przeciwieństwie do klasycznych sieci konwolucyjnych, które przetwarzają lokalne sąsiedztwo pikseli na regularnej siatce obrazu, modele *GCN* operują w przestrzeni nieeuklidesowej, agregując informacje bezpośrednio z połączonych węzłów grafu. Co kluczowe dla systemów rekomendacyjnych, w tym modelu celowo zrezygnowano z transformacji cech oraz nieliniowych funkcji aktywacji, pozostawiając jedynie mechanizm liniowej propagacji osadzeń (ang. *embeddings*) wzdłuż krawędzi grafu.

Model ten opiera się operacjach na grafie dwudzielnym $G = (V, E)$, gdzie $V = U \cup I$, gdzie V to zbiór węzłów zawierający wszystkich użytkowników U (ang. *users*) i przedmiotów I (ang. *items*), a E to zbiór krawędzi reprezentujących interakcje pomiędzy nimi.

Każdą relację przedstawiamy w postaci macierzy interakcji R o rozmiarze M (to liczba użytkowników) ma N (to liczba przedmiotów), gdzie $R_{ui} = 1$ oznacza, że użytkownik u nawiązał interakcję z przedmiotem i , a 0 w przeciwnym wypadku. Za pomocą tak zbudowanej macierzy tworzymy macierz sąsiedztwa A faktycznie używaną w operacjach macierzowych:

$$A = \begin{pmatrix} 0 & R \\ R^T & 0 \end{pmatrix} \quad (2.1)$$

Celem modeli typu *collaborative filtering* jest nauczenie optymalnych *embeddingów* użytkowników e_u i przedmiotów e_i , które utrwalają relację i podobieństwo między nimi, dlatego w każdej warstwie czerpią one informacje od swoich sąsiadów. Warto zaznaczyć, że wektory osadzeń $e_u^{(0)}$ i $e_i^{(0)}$ z warstwy zerowej są jedynymi parametrami modelu, które zmieniają się w czasie treningu. Ich propagacja przebiega następująco:

$$e_u^{(l+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u| \cdot |\mathcal{N}_i|}} e_i^{(l)}, \quad e_i^{(l+1)} = \sum_{u \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_u| \cdot |\mathcal{N}_i|}} e_u^{(l)} \quad (2.2)$$

gdzie $\mathcal{N}$ to oznaczenie sąsiedztwa węzła, a $e^{(l)}$ to węzeł z warstwy l . Symetryczna norma $\frac{1}{\sqrt{|\mathcal{N}_u| \cdot |\mathcal{N}_i|}}$ używana jest w celu zapobiegania niekontrolowanej skali *embeddingów* wraz z zwiększaniem się warstw, czyli operacji konwolucji.

Finalne reprezentacje wektorów są pozyskiwane po połączeniu *embeddingów* ze wszystkich warstw:

$$e_u = \sum_{l=0}^L \alpha_l e_u^{(l)}, \quad e_i = \sum_{l=0}^L \alpha_l e_i^{(l)} \quad (2.3)$$

Wszystkie te operacje zapisujemy w macierzowej formie, żeby przyspieszyć obliczenia. Niech $E^{(l)}$ ma rozmiary $(M + N) \times D$ (D to długość *embeddingu*), P jest macierzą stopni węzłów o rozmiarach $(M + N) \times (M + N)$. Do operacji jest nam również potrzebna znormalizowana macierz sąsiedztwa, którą definiujemy tak:

$$\tilde{A} = P^{-0.5} \cdot A \cdot P^{-0.5} \quad (2.4)$$

Po zmienionych oznaczeniach propagacja przebiega za pomocą tych operacji:

$$E^{(l+1)} = \tilde{A}E^{(l)} = \tilde{A}^{l+1}E^{(0)} \quad (2.5)$$

Finalna macierzowa formuła na reprezentacje wektorów użytkowników i przedmiotów liczymy tak:

$$\begin{aligned} E &= \alpha_0 E^{(0)} + \alpha_1 E^{(1)} + \dots + \alpha_l E^{(l)} = \\ &= \alpha_0 E^{(0)} + \alpha_1 \tilde{A}^1 E^{(0)} + \dots + \alpha_l \tilde{A}^l E^{(0)} \end{aligned} \quad (2.6)$$

Autorzy *LightGCNa* używają każdego α jako tej samej wartości, czyli $\frac{1}{L+1}$, aby uniknąć komplikowania i zachowania prostoty modelu.

Wyniki predykcji interakcji użytkownik–przedmiot obliczane są jako iloczyn skalarny wektorów:

$$\hat{y}_{ui} = e_u^T e_i, \quad (2.7)$$

które używane są do wygenerowania K najlepszych rekomendacji dla każdego użytkownika.

Model optymalizuje *embeddingi* za pomocą funkcji straty nazywanej *Bayesian Personalized Ranking (BPR)*. Używa ona par predykcji: pozytywnej $\hat{y}_{ui}$ (interakcja użytkownika z przedmiotem zaszła) i negatywnej $\hat{y}_{uj}$ (interakcji nie było). Jej celem jest uzyskanie jak największej różnicy pomiędzy nimi, czyli jak największej wartości dla przedmiotu pozytywnego i jak najmniejszej dla negatywnego:

$$L_{BPR} = - \sum_{u \in U} \sum_{i \in \mathcal{N}_u} \sum_{j \notin \mathcal{N}_u} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) + \lambda \|E^{(0)}\|^2, \quad (2.8)$$

gdzie λ kontroluje siłę L_2 regularyzacji, a σ to funkcja sigmoidalna $\left(\sigma(x) = \frac{1}{1+e^{-x}}\right)$.

Rozdział 3.

Definicja problemu

Jednym z kluczowych problemów współczesnych systemów rekomendujących jest skrzywienie ku popularności tzw. *Popularity Bias*. Zjawisko to polega na nieproporcjonalnym promowaniu przedmiotów o najwyższej popularności (bestsellery, hity), ignorując przy tym pozycje mniej znane, nawet jeśli te niszowe byłyby obiektywnie lepszym i bardziej trafnym wyborem dla danego użytkownika.

Źródła tego zjawiska można analizować z wielu perspektyw, jednak w niniejszej pracy koncentrujemy się przede wszystkim na dwóch z nich: *data bias* oraz *model bias* [7]. Taki wybór wynika bezpośrednio z charakteru proponowanych metod mitygacji, które ingerują z jednej strony w strukturę grafu interakcji, a z drugiej w funkcję uczącą i sposób generowania sygnału optymalizacyjnego.

3.1. Błąd danych

Błąd danych (ang. *data bias*) to skrzywienie obecne na poziomie danych treningowych. Algorytmy bardzo rzadko uczone są na pełnej informacji o rzeczywistych preferencjach użytkowników. W praktyce korzystają one głównie z wcześniej wspomnianych (w rozdziale 1.) danych ukrytych, które są zaszumione i ich brak nie oznacza automatycznie negatywnej preferencji, lecz często jedynie brak ekspozycji na ten obiekt.

W tym sensie dane treningowe są obciążone historyczną polityką ekspozycji systemu. Przedmioty bardziej widoczne, promowane lub częściej umieszczane wysoko w rankingach zbierają więcej interakcji niezależnie od swojej rzeczywistej istotności. W literaturze zjawisko to opisuje się między innymi za pomocą pojęć takich jak *exposure bias* czy *position bias*. Wspólną cechą tych mechanizmów jest to, że obserwowane dane nie stanowią czystego zapisu preferencji użytkownika, lecz mieszaninę preferencji i warunków, w jakich użytkownik miał okazję zetknąć się z danym przedmiotem.

Innym przejawem tego problemu jest nierównowaga popularności. Popularne

przedmioty generują znacznie więcej interakcji niż obiekty należące do długiego ogona, przez co są nadreprezentowane w danych uczących. W rezultacie model otrzymuje znacznie więcej przykładów potwierdzających znaczenie hitów niż przykładów opisujących zachowanie niszy.

3.2. Błąd modelu

Błąd modelu (ang. *model bias*) to skrzywienie powstające w samym procesie uczenia. Algorytmy rekomendacyjne uczą się na podstawie częstości oraz struktury obserwowanych interakcji, dlatego obiekty częściej występujące w danych są aktualizowane częściej i silniej niż przedmioty rzadkie. Ich reprezentacje wektorowe zbiegają szybciej, są lepiej oszacowane i uzyskują bardziej stabilną pozycję w przestrzeni osadzeń, podczas gdy przedmioty niszowe pozostają słabiej opisane z powodu ograniczonej liczby obserwacji.

Z perspektywy optymalizacji jest to dla modelu rozwiązanie „bezpieczne”, ponieważ funkcja straty premiuje wzorce najczęściej obecne w danych, co pozwala poprawiać globalne metryki nawet wtedy, gdy odbywa się to kosztem jakości personalizacji dla elementów długiego ogona.

W systemach opartych na grafowych sieciach neuronowych mechanizm ten może być dodatkowo wzmacniany przez topologię grafu: popularne przedmioty mają zwykle wyższy stopień, częściej uczestniczą w propagacji sąsiedztwa i tym samym silniej wpływają na końcowe reprezentacje osadzeń. W konsekwencji model nie tylko odzwierciedla istniejącą nierównowagę danych, lecz również utrwała ją i wzmacnia poprzez sam mechanizm uczenia.

3.3. Znaczenie błędu popularności

Zwalczanie *Popularity Bias* ma istotne znaczenie zarówno z perspektywy użytkownika, jak i dostawcy rekomendacji. Dla użytkownika nadmierne promowanie hitów oznacza spadek nowości, ograniczenie personalizacji oraz mniejszą szansę na odkrycie przedmiotów lepiej dopasowanych do jego indywidualnych, często niszowych preferencji. System staje się przez to bardziej przewidywalny i mniej użyteczny, ponieważ zamiast wspierać proces odkrywania, wielokrotnie ekspozuje tę samą wąską grupę popularnych obiektów.

Z perspektywy dostawcy rekomendacji problem ten ma również bardzo wymiar praktyczny i ekonomiczny. Platforma dysponuje zwykle szerokim katalogiem produktów, z których znaczna część należy do długiego ogona, a więc do grupy przedmiotów rzadziej wybieranych i słabiej ekspozowanych. Jeżeli system konsekwentnie promuje wyłącznie hity, to znaczna część zasobów magazynowych, ofertowych lub treściowych pozostaje niewykorzystana, zajmuje miejsce i generuje ryzyko strat. Ograni-

czanie *Popularity Bias* pozwala więc nie tylko poprawić trafność rekomendacji dla użytkownika, ale również efektywniej monetyzować niszową część katalogu i lepiej wykorzystywać pełne spektrum dostępnej oferty.

W tym kontekście szczególnie istotne staje się zjawisko *rediscovered gems*, czyli ponownego odkrywania wartościowych, lecz wcześniej niedostatecznie eksponowanych przedmiotów. Dla użytkownika oznacza to większą szansę na znalezienie trafnych i mniej oczywistych rekomendacji, natomiast dla platformy stanowi możliwość aktywizacji zalegających zasobów oraz wydobywania wartości z elementów katalogu, które bez odpowiedniego wsparcia rekomendacyjnego pozostałyby pominięte.

Celem niniejszej pracy jest zbadanie możliwości ograniczania zjawiska *Popularity Bias* poprzez osłabienie jego dwóch powyższych źródeł. W szczególności praca koncentruje się na modyfikacji funkcji uczącej oraz zmianie struktury grafu interakcji w trakcie treningu modelu.

Rozdział 4.

Krótki przegląd literatury

W literaturze opisywane są trzy kategorie łagodzenia *Popularity Bias* na podstawie czasu w jakim dana metoda jest używana. Rozróżniamy: przed treningiem (ang. *pre-processing*), w czasie treningu (ang. *in-processing*) oraz po treningu (ang. *post-processing*).

Podjęcia *pre-processing* modyfikują dane wejściowe lub zbiór kandydatów jeszcze przed właściwym uczeniem albo rankingowaniem. Należą do nich między innymi przeważanie przykładów związanych z elementami niszowymi, resampling interakcji oraz ograniczanie wpływu obiektów bardzo popularnych. Jako ilustrację takiej interwencji można wskazać pracę **Cremonesiego i innych** [3], w której analizowany jest scenariusz usunięcia elementów należących do *short head*, przez co system operuje wyłącznie na obiektach z *long tail*.

Podjęcia *in-processing* ingerują bezpośrednio w mechanizm uczenia modelu. Najczęściej obejmują one modyfikację funkcji straty, dodanie regularyzacji lub zmianę strategii samplingu, tak aby model nie wzmacniał nadmiernie obiektów popularnych. Przykładem jest praca **Koneru i innych** [8] dla modelu *SASRec* [6], gdzie zastosowano funkcję straty *gBCE*, zmodyfikowane próbkowanie negatywów oraz strategię *top-k negative sampling*, co pozwoliło ograniczyć *Popularity Bias* i jednocześnie poprawić wskaźniki biznesowe.

Podjęcia *post-processing* działają już po wytrenowaniu modelu i korygują gotowy ranking lub końcowe wyniki rekomendacji. W tej grupie mieszczą się przede wszystkim metody *re-rankingu* oraz różne warianty kompensacji popularności, których zaletą jest łatwość wdrożenia bez konieczności ponownego trenowania modelu. Taki mechanizm zaproponowali **Zhu i inni** [13] w metodzie *Popularity Compensation*, gdzie końcowe oceny są korygowane z uwzględnieniem popularności przedmiotu oraz przewidywanej preferencji użytkownika.

Z punktu widzenia niniejszej pracy szczególnie istotne są metody *in-processing*, ponieważ pozwalają wpływać bezpośrednio na dynamikę uczenia modelu. W modelach grafowych przewaga popularnych przedmiotów może być wzmacniana przez

propagację informacji w grafie, agregację sąsiedztwa oraz częstotliwość aktualizacji *embeddingów*, dlatego modyfikacja samego procesu optymalizacji wydaje się tutaj szczególnie uzasadniona.

Rozdział 5.

Proponowane podejścia

Opierając się na klasyfikacji metod łagodzenia *Popularity Bias* opisanej w rozdziale 4., w niniejszej pracy skupiamy się na technikach z kategorii in-processing. Zaprojektowane rozwiązanie opiera się dwóch filarach. Pierwszy z nich dotyczy zmiany mechanizmu oceniania przedmiotów, ze szczególnym uwzględnieniem ochrony przedmiotów z długiego ogona. Drugi filar koncentruje się na strukturalnej regularyzacji grafu (ang. *dropout*), która polega ona stochastycznym usuwaniu informacji (np. krawędzi i wierzchołków).

5.1. Smoothed BPR

Pierwszą z nich jest modyfikacja procesu pobierania próbek negatywnych w algorytmie *BPR*. Standardowo metoda ta losuje każdy przedmiot (popularny i rzadki) według rozkładu jednostajnego (tj. $p = \frac{1}{M}$). Tych drugich jest znacznie więcej, co powoduje, że są często wybierane jako przykłady negatywne. W tej sytuacji model uczy się ich nie rekomendować, ponieważ hity bez trudu z nimi wygrywają, obniżając ich wynik rekomendacji. Problem ten pogłębia się, kiedy pozytywna nisza walczy z inną negatywną niszą o swoją pozycję w rankingu. Zjawisko to nazywamy *Gradient Starvation*. Polega ono na tym, że model koncentruje się na nauczaniu się najłatwiejszych cech (najszybciej obniżają funkcję straty (ang. *loss function*)), pomijając ukryte cechy prowadzące do generalizacji, co objawia się przez *Popularity Bias*.

Smoothed BPR (SBPR) to metoda, która częściowo leczy ten problem. Polega ona na zmianie rozkładu, z którego losowane są negatywne przedmioty. Rozkład prawdopodobieństwa jest obliczany tak:

$$P(i) = \frac{deg_i^\alpha}{\sum_{j \in I} deg_j^\alpha}, \quad (5.1)$$

gdzie: α to parametr wygładzenia, do którego podnosimy każdy ze stopni przedmiotów, a deg_i oznacza stopień przedmiotu i .

Wprowadzony parametr α służy do zwiększania częstości losowania popularnych przedmiotów, dzięki czemu przedmioty te rywalizują z innymi popularnymi o swoją pozycję, a rzadkie mają szansę zostać relatywnie wyżej w rekomendacjach, ponieważ nie są już tak bardzo zaniżane.

Powyższy sposób nie eliminuje całkowicie problemu *Gradient Starvation*. Parametr wygładzenia zajmuje się losowaniem negatywów, ale hity dominują jako pozytywne w danych treningowych, w rezultacie aktualizują one swoje wektory z nieproporcjonalnie większą siłą niż niszowe. W następnej sekcji omówimy, jak wyrównać tę dysproporcję.

5.2. Inverse Propensity Scoring

Inverse Propensity Scoring (IPS) to technika statystyczna wywodząca się z badań jakie realne skutki wywołały podjęte działania. W kontekście systemów rekomendujących, analizujemy wpływ strategii treningu na ekspozycję danych przedmiotów w rekomendacjach i ich jakość. Nasza metoda polega na ważeniu funkcji straty odwrotnie proporcjonalnie do popularności przedmiotu pozytywnego, co nazywamy estymatorem jego szansy na ekspozycję (ang. *propensity score*). Każda z wag przedmiotów obliczana jest na podstawie poniższego wzoru:

$$w_i = \min \left(\frac{\max_{j \in I} \deg_j}{\deg_i}, C \right), \quad (5.2)$$

gdzie C to maksymalna dopuszczalna wartość wagi (próg odcięcia). Wagi te aplikujemy do zmodyfikowanego *BPR*:

$$L_{IPS} = - \sum_{u \in U} \sum_{i \in N_u} \sum_{j \notin N_u} w_i \cdot \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) + \lambda \|E^{(0)}\|^2, \quad (5.3)$$

gdzie zmienne λ , σ , $\hat{y}$ zostały określone we wzorze 2.8.

Parametr C zapewnia, żeby waga nie osiągnęła ekstremalnych wartości dla przedmiotów bardzo niszowych. Brak takiego podejścia mógłby spowodować gwałtowny skok wariancji gradientu i destabilizację optymalizatora równoważny załamaniu się procesu uczenia.

Dzięki temu mechanizmowi, sygnał uczenia dla niszowych przedmiotów pozytywnych wzmacnia się, co umożliwia im lepiej konkurować z hitami w rankingu. Metoda ta doskonale dopełnia *Smoothed BPR* - podczas gdy ten pierwszy osłabia pozycję przedmiotów popularnych negatywnych, *IPS* skupia się na korekcie wag dla przedmiotów pozytywnych.

5.3. FastLightGCN

5.3.1. Eksplozja sąsiedztwa i ograniczenia pełnej propagacji

Metoda **FastGCN** [2] została pierwotnie zaprojektowana, aby rozwiązać problem eksplozji sąsiedztwa (ang. *Neighborhood Explosion*), czyli wykładniczego wzrostu liczby agregowanych wierzchołków w głębokich warstwach spłotowych. Stanowi to jedno z najbardziej krytycznych wyzwań wydajnościowych w obszarze grafowych sieci neuronowych. Z natury tej architektury faza propagacji osadzeń wymaga zazwyczaj obecności całego grafu w pamięci operacyjnej. W przypadku ogromnych grafów przemysłowych jest to często technicznie niemożliwe ze względu na wymogi skalowalności systemów oraz nieakceptowalny koszt pamięciowy i czasowy uczenia modelu.

W kontekście systemów rekomendujących, pełna agregacja sąsiadów prowadzi do ubocznego, poważnego ryzyka - może drastycznie propagować i wzmacniać zjawisko *Popularity Bias*. Wynika to z faktu, że hity dominują w tym procesie i znacznie silniej wpływają na końcowe reprezentacje wektorowe.

5.3.2. Aproksymacja warstwy spłotowej metodą Monte Carlo

Aby zniwelować powyższe ograniczenia, wprowadzono stochastyczny model uczenia, polegający na warstwowym próbkowaniu węzłów (ang. *layer-wise sampling*), eliminujący konieczność pełnej agregacji całego sąsiedztwa. Umożliwienie losowania niezależnych próbek bez łamania ciągłości propagacji wymagało redefinicji klasycznego spłotu grafowego. Zamiast operacji dyskretnego mnożenia rzadkich macierzy, propagację osadzeń zinterpretowano jako ciągłe przekształcenie całkowe (ang. *integral transform*) względem miary prawdopodobieństwa. Zmiana tego paradygmatu otworzyła drzwi do wykorzystania estymatorów **Monte Carlo** - warstwa staje się aproksymacją całki na podstawie losowania podzbioru węzłów. W szerszym kontekście architektonicznym, metoda ta stanowi zaawansowaną formę strukturalnego *dropoutu*.

W celu minimalizacji wariancji estymatora autorzy oryginalnej metody wprowadzili technikę **Importance Sampling**. Zamiast losować węzły z prawdopodobieństwem jednostajnym, prawdopodobieństwo wyboru danego wierzchołka u , oznaczone jako $q(u)$, zostało definiowane proporcjonalnie do jego stopnia:

$$q(u) = \left\| \tilde{A}(:, u) \right\|^2 / \sum_{u' \in V} \left\| \tilde{A}(:, u') \right\|^2 \approx \frac{\deg_u^2}{\sum_{u' \in V} \deg_{u'}^2}, \quad (5.4)$$

gdzie $\tilde{A}$ zostało zdefiniowane we wzorze 2.4. Przy zastosowaniu tego rozkładu aktualizacja w ukrytej warstwie $l + 1$ obliczana jest na podstawie wylosowanej niezależnie próbki węzłów o ustalonym rozmiarze t_l :

$$H^{(l+1)}(v, :) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \frac{\tilde{A}(v, u_j^{(l)}) H^{(l)}(u_j^{(l)}, :) W^{(l)}}{q(u_j^{(l)})} \right) \quad (5.5)$$

gdzie $H^{(l)}(u_j^{(l)}, :)$ to osadzenia wężła u_j wybranego w warstwie l .

5.3.3. Wady oryginalnego modelu próbkowania

Powyższy algorytm skutecznie eliminuje problem *Neighborhood Explosion*, wspierając optymalizację paczkami (ang. *mini-batch*). Niemniej jednak adaptacja tego rozwiązania do środowiska rzadkich grafów rekomendujących ujawnia dwie kardynalne wady.

Po pierwsze, mechanizm *Importance Sampling* (zdefiniowany w Równaniu 5.4) z definicji faworyzuje hity, które wielokrotnie więcej trafiają do puli losowania. W efekcie metoda powiększa dystans w normach L_2 osadzeń pomiędzy popularnymi a niszowymi przedmiotami, wprost pogłębiając zjawisko *Popularity Bias*.

Po drugie, architektura *FastGCN* była ewaluowana na stosunkowo gęstych grafach homogenicznych (np. sieci cytowań *Cora*¹ i *Pubmed*¹ lub społecznościowych jak *Reddit*²), gdzie niezależne losowanie węzłów dla poszczególnych warstw nie zaburzało ciągłości propagacji. Jednakże w przypadku rzadkich grafów heterogenicznych (np. typu *user-item*), prawdopodobieństwo wystąpienia fizycznej krawędzi pomiędzy wierzchołkiem losowo wybranym w warstwie $l + 1$ a wierzchołkiem z warstwy l jest bliskie zeru. Zdecydowana większość krawędzi $\tilde{A}(v, u_j^{(l)})$ wynosi zero, doprowadzając do braku przepływu gradientu podczas propagacji wstecznej, które efektywnie paraliżuje proces optymalizacji.

5.3.4. Modyfikacja estymatora w architekturze FastLightGCN

W celu obiektywnego zbadania wpływu mechanizmów próbkowania na łagodzenie *Popularity Bias*, zachowaliśmy zgodność architektoniczną z pierwotnym modelem bazowym (ang. *baseline*), czyli *LightGCN*. Podczas projektowania zoptymalizowanego estymatora zrezygnowaliśmy z operacji uczenia się macierzy wag transformacji $W^{(l)}$ oraz nieliniowych funkcji aktywacji. Powyższy model ich nie wykorzystuje, a jego oryginalni twórcy udowodnili, że w rzadkich grafach systemów rekomendujących elementy te sprzyjają przeuczeniu (ang. *overfitting*), podczas gdy liniowa, bezwagowa agregacja jest w zupełności wystarczająca.

W ramach pracy zaprojektowaliśmy autorską modyfikację mechanizmu selekcji wierzchołków o nazwie **FastLightGCN**. W celu przywrócenia stabilnego przepływu gradientu estymator wykorzystuje warunkowe próbkowanie w oparciu o lokalną topologię sieci. Koncepcja ta polega na losowaniu zbioru węzłów warstwy l wyłącznie

¹<https://github.com/tkipf/gcn>

²<https://snap.stanford.edu/graphsage/>

spośród sąsiadów węzłów wyselekcjonowanych w warstwie $l + 1$. Została ona, po raz pierwszy, formalnie zaproponowana w architekturze *LADIES* (Layer-Dependent Importance Sampling) [14].

Zmianie podlega również dystrybucja prawdopodobieństwa, z której losowany jest zbiór wierzchołków. Klasyczny rozkład wprost promuje obiekty o najwyższych stopniach. Aby mu przeciwdziałać, zaproponowaliśmy mechanizm **Smoothed Importance Sampling (SIS)**, inspirowany rozwiązaniem z rozdziału 5.1. Prawdopodobieństwo wyboru wierzchołka u (dla warstwy l) warunkowane jest zbiorem węzłów z warstwy wyższej $\mathcal{V}^{(l+1)}$. Definiujemy sąsiedztwo tej warstwy jako sumę wszystkich sąsiadów:

$$\mathcal{N}(\mathcal{V}^{(l+1)}) = \bigcup_{v \in \mathcal{V}^{(l+1)}} \mathcal{N}(v) \quad (5.6)$$

Prawdopodobieństwo wylosowania węzła u z tak zdefiniowanej puli jest następnie wygładzane poprzez podniesienie liczności każdego z jego sąsiadów do potęgi α :

$$P_{SIS}(u|\mathcal{V}^{(l+1)}) = \frac{|\mathcal{N}(u)|^\alpha}{\sum_{v \in \mathcal{N}(\mathcal{V}^{(l+1)})} |\mathcal{N}(v)|^\alpha} \quad (5.7)$$


Parametr α umożliwia kontrolę nad wpływem stopnia wierzchołka na jego szansę wylosowania. Podejście to dekompresuje strukturę i w pewnym stopniu odbiera hitom dominację probabilistyczną, pozwalając modelowi na większą eksplorację przedmiotów z długiego ogona.

Zredukowana propagacja modelu *FastLightGCN* realizowana jest na podstawie dynamicznie budowanych, rzadkich podgrafów dwudzielnych (ang. *bipartite subgraphs*). W każdej warstwie konstruowana jest macierz przejścia $A_{sub}^{(l)}$, definiująca przepływ informacji pomiędzy węzłami agregującymi $\mathcal{V}^{(l+1)}$ (cel) a wylosowaną warstwą sąsiadów $\mathcal{V}^{(l)}$ (źródło). Wiersze reprezentują odbiorców sygnału kolaboratywnego (ang. *collaborative signal*), a kolumny nadawców. Każda krawędź tej macierzy jest odpowiednio skalowana estymatorem *Monte Carlo*. Przekształcenie warstwy ukrytej wyraża się wówczas operacją macierzową:

$$\tilde{A}_{sub}^{(l)} = \frac{A_{sub}^{(l)}}{t_l} \cdot \text{diag} \left(\left[\frac{1}{P_{SIS}(u|\mathcal{V}^{(l+1)})} \right]_{u \in \mathcal{V}^{(l)}} \right) \quad (5.8)$$

gdzie $t_l = |\mathcal{V}^{(l)}|$ to hiperparametr określający rozmiar (liczbę węzłów) próbkowanej warstwy l .

$$H_{batch}^{(l)} = \left(\prod_{i=0}^{x-l} \tilde{A}_{sub}^{x-i} \right) H^{(0)}(\mathcal{V}^{(l)}), \quad \text{gdzie } x = L - 1 \quad (5.9)$$



Rysunek 5.1: Schemat warstwowego próbkowania, którego propagacja odbywa się od najniższej warstwy do najwyższej, ale losowanie węzłów odbywa się w odwrotnej kolejności. Każdy *embedding* z wylosowanego zbioru węzłów dla danej warstwy jest odpowiednio przekształcany przez macierze przejścia $A^{(L-1)}$, której rozmiary to $t_{L-1} \times t_L$.

gdzie *batch* to wierzchołki z paczki (inaczej $\mathcal{V}^{(L)}$), $H_{batch}^{(l)}$ to macierz zagregowanych osadzeń wierzchołków z paczki w warstwie l , $H^{(0)}(\mathcal{V}^{(l)})$ to osadzenia dla węzłów wylosowanych w warstwie l , a L to liczba warstw w modelu.

Macierz diagonalna kompensuje zaburzenie wartości oczekiwanej wynikające z pominięcia rzadziej losowanych wierzchołków w dystrybucji P_{SIS} . Ostateczna macierz reprezentacji używana do predykcji preferencji stanowi średnią z osadzeń na każdym etapie warstwowego próbkowania:

$$H_{final} = \frac{1}{L+1} \sum_{l=0}^L H_{batch}^{(l)} \quad (5.10)$$

Dodatkowo, aby zapobiec tworzeniu się zamkniętych cykli propagacyjnych (np. typu $u \rightarrow i \rightarrow u$), które sztucznie wzmacniałyby sygnał najpopularniejszych przedmiotów, zastosowaliśmy mechanizm próbkowania bez zwracania utrzymując globalny zbiór wylosowanych wierzchołków $\mathcal{V}$. Wymusza on unikalność wierzchołków pobiera-

nych w ramach danej paczki, co wprost zapobiega redundantnemu i wielokrotnemu wybieraniu hitów.

Uwzględniając bezwagowy charakter architektury bazowej, dystrybucję w oparciu o zdefiniowany rozkład *SIS*, uwarunkowanie topologiczne oraz narzuconą unikalność próbkowania można stwierdzić, że model zmuszony jest do budowania stabilnych osadzeń bez polegania wyłącznie na gęstym sąsiedztwie hitów.

5.4. Błądzenie losowe PinSage’a i dropouty

Model **PinSage** [12] został zaprojektowany w podobnym celu jak *FastGCN*: oba podejścia mają na celu ograniczenie kosztu obliczeniowego oraz szumu pojawiającego się podczas uczenia grafowych sieci neuronowych na bardzo dużych grafach. W przeciwieństwie do klasycznych grafowych sieci konwolucyjnych, *PinSage* nie wykorzystuje pełnego sąsiedztwa węzła, lecz konstruuje lokalny, losowo próbkowany podgraf. Próbkowanie to odbywa się za pomocą krótkich ścieżek błądzenia losowego (ang. *random walks*), uruchamianych z każdego węzła należącego do paczki uczącej. Dla każdego węzła generuje się T ścieżek (ang. *traces*) o ustalonej długości H (ang. *hops*), a następnie zlicza się częstość odwiedzin poszczególnych węzłów. Na tej podstawie wybieranych jest K najczęściej odwiedzanych sąsiadów, którym nadawane są wagi używane w dalszej agregacji informacji (tzw. *importance pooling*).

Takie podejście można interpretować jako rodzaj dropoutu na poziomie struktury grafu. Zamiast pełnego sąsiedztwa węzła model widzi jedynie próbkę lokalnego otoczenia, co zmienia rozkład informacji docierającej do warstw agregujących oraz odfiltrowuje przypadkowe połączenia i zostawia tylko te, które są istotne strukturalnie.

Na tej podstawie zaimplementowaliśmy autorski mechanizm próbkowania dla całego grafu, różniący się od *PinSage* tym, że stosowany jest jednocześnie do wszystkich węzłów. Polega on na tym, że K najczęściej odwiedzanych sąsiadów każdego węzła staje się jego bezpośrednimi sąsiadami w nowej macierzy sąsiedztwa A . Zredukowana w ten sposób macierz musi następnie zostać na nowo znormalizowana symetrycznie, jak we wzorze 2.4. Dodatkowym parametrem regularyzacyjnym jest częstotliwość przebudowy grafu (co X epok). Oznacza to, że model nie uczy się stale na identycznej strukturze, lecz okresowo otrzymuje nową macierz sąsiedztwa, co wprowadza pożądaną stochastyczność i zapobiega przeuczeniu do jednej, sztywnej topologii.

Intuicyjnie ogranicza to dominację bardzo gęstych obszarów grafu, rozrzedzając ich strukturę. Jednocześnie zwiększa to względną rolę węzłów z mniej licznych fragmentów struktury, zyskując sztucznych sąsiadów, wzbogacając ich *embedingi*. Dzięki temu rozkład stopni w zbiorze treningowym jest bardziej równomierny, co osłabia zjawisko *Popularity Bias*.

Innymi sposobami na regularyzację grafu są *Edge Dropout* oraz *Node Dropout*. Zarówno pierwszy, jak i drugi mechanizm polega na czasowym usuwaniu elementów struktury grafu w każdej epoce z prawdopodobieństwem odrzucenia p , nie zapominając o przeskalowaniu zachowanych wartości przez czynnik $\frac{1}{1-p}$, aby zachować wartość oczekiwaną sygnału. W przypadku pierwszego usuwane są pojedyncze krawędzie, natomiast drugi usuwa cały węzeł wraz ze wszystkimi incydentnymi krawędziami.

O ile samo usunięcie krawędzi skutkuje zmniejszeniem tempa przyrostu normy osadzeń L_2 dla popularnych elementów, pozwalając na stabilniejszą naukę relacji w długim ogonie, o tyle usunięcie węzła jest bardziej radykalne, ponieważ usuwa wszystkie krawędzie z nim związane, wymuszając jeszcze silniejszą dywersyfikację reprezentacji i wyodrębnienie zależności dla przedmiotów niszowych. Pozwala to spojrzeć z innej strony na problem *Popularity Bias*.

Rozdział 6.

Eksperymenty

6.1. Dane treningowe

Do ewaluacji wymienionych w poprzednim rozdziale metod wykorzystujemy zbiór danych (ang. *dataset*) *Gowalla*¹, który został przygotowany przez twórców architektury *NGCF* [11] i również zaadaptowany między innymi przez autorów modelu *LightGCN* [4]. *Dataset* został stworzony zgodnie ze zasadami obejmującymi filtrowanie i podział danych. Oryginalny zbiór został pozbawiony węzłów (użytkowników, przedmiotów) z mniej niż 10 interakcjami (ang. *10-core filtering*) w globalnym grafie. Dla każdego użytkownika, zostało losowo przypisanych 80% jego historycznych interakcji, a pozostałe 20% tworzy dane testowe. W Tabeli 6.1 zostały przedstawione szczegółowe rozmiary danych.

	Zbiór danych	Zbiór treningowy	Zbiór testowy
Liczba interakcji	1 027 370	810 128	217 242
Unikalne przedmioty	40 981	40 981	38 546
Liczba użytkowników	29 858	29 858	29 858
Gęstość macierzy	0.00084	0.00066	0.00019

Tabela 6.1: Informacje o zbiorach danych Gowalla po zastosowaniu preprocessingu.

W Tabeli 6.2 oraz na Rysunku 6.1 zaprezentowano informacje odnośnie popularności w zbiorze treningowym (na ich podstawie zdefiniowane zostaną grupy decylowe omawiane w podrozdziale 6.3.). Interpretacja tych danych pokazuje wprost uwarunkowanie topologiczne będące bezpośrednim dowodem na zjawisko *Popularity Bias*.


Znacząco przykuwa uwagę niewielka różnica pomiędzy średnią a medianą popularności przedmiotów. Średnia jest silnie zawyżona przez małą liczebność ekstremalnie popularnych węzłów (tzw. *hubów*), a niska mediana wykazuje, że ogromna

¹<https://snap.stanford.edu/data/loc-gowalla.html>

większość (ponad połowa) elementów ma niewielki wkład w liczbę wszystkich powiązań. Taką dystrybucję danych określa się jako rozkład potęgowy (ang. *power-law distribution*).

	Popularność użytkowników	Popularność przedmiotów
Minimum	8	1
Maksimum	811	1415
Mediana	16	12
Średnia	27.13	19.77

Tabela 6.2: Statystyka popularności użytkowników i przedmiotów w zbiorze treningowym.



Rysunek 6.1: Histogram popularności zbioru treningowego. Oś Y została przeskalowana do logarytmicznych rozmiarów dla lepszej czytelności.

6.2. Proces treningowy

W celu zachowania rzetelnego i obiektywnego środowiska testowego (ang. *fair baseline comparison*) oraz izolacji wpływu badanych technik, zrezygnowaliśmy z przeszukania przestrzeni podstawowych hiperparametrów (ang. *hyperparameter tuning*). W zamian, we wszystkich testowanych rozwiązaniach – zarówno w modelu bazowym, jego wariantach z próbkowaniem grafu (*FastGCN* [2], *PinSage* [12]), jak i w modyfikacjach funkcji straty (*IPS* i *SBPR*) – przyjęliśmy optymalne wartości znalezione eksperymentalnie przez twórców *LightGCN*.

W Tabeli 6.3 zestawiono wszystkie wspólne parametry. Takie podejście metodologiczne zapewnia, że zaobserwowane zmiany w metrykach ewaluacyjnych (zwłaszcza w grupach decylowych), wynikają tylko i wyłącznie przez zastosowane techniki mitygacji *Popularity Bias*, a nie przez różnice w ustawieniach modelu.

Parametr	Wartość
Liczba warstw L (ang. <i>layers</i>)	4
Wymiar osadzeń D (ang. <i>embedding size</i>)	64
Inicjalizacja osadzeń	$\mu = 0.0, \sigma = 0.1$
Rozmiar paczki (ang. <i>batch size</i>)	2048
Optymalizator	Adam
Współczynnik uczenia (ang. <i>learning rate</i>)	10^{-3}
Regularyzacja L_2 (ang. <i>weight decay</i>)	10^{-4}
Maksymalna liczba epok	1000
Ziarno losowości (ang. <i>seed</i>)	2020

Tabela 6.3: Zestawienie podstawowych hiperparametrów procesu uczenia współdzielonych pomiędzy eksperymentami. Osadzenia zostały zainicjalizowane za pomocą rozkładu normalnego. W *FastLightGCN* *batch size* jest specyficznym parametrem, który wpływa na strukturę modelu, dlatego jego wpływ omawiamy w rozdziale 6.4.3.

Jak udowodniono w pracy bazowej, wyżej wymieniona wartość kary regularizacyjnej L_2 w zupełności wystarcza, żeby uniknąć *overfittingu*. Pozwala to na całkowite pominięcie mechanizmów takich jak, odrzucanie węzłów (ang. *node dropout*) oraz krawędzi (ang. *edge dropout*) stosowanych w m.in. w architekturze *NGCF*.

6.3. Metryki

Głównym celem tej pracy jest analiza wpływu opisanych powyżej poszczególnych metod mitygacji na zjawisko Popularity Bias. Aby należycie ocenić jakość rekomendacji, przedmioty zostały posortowane malejąco na podstawie ich popularności (liczby interakcji) i dzielone na dziesięć równolicznych decyli. Następnie, na potrzeby ewaluacji, decyle te zagregowano w trzy rozłączne grupy o oznaczeniu *gr*:

- **Top 20% (*Head*):** zbiór najbardziej popularnych przedmiotów (tzw. hity lub „głowa”),
- **Middle 60%:** przedmioty o średniej popularności,
- **Bottom 20% (*Long Tail*):** zbiór najmniej popularnych przedmiotów (tzw. nisza lub długi „ogon”).

Zastosowanie takiego podziału jest istotne dla obu rodzajów metryk, z których korzystamy w pracy. Standardowe, globalne uśrednianie metryk uniemożliwia nam dokładne zdiagnozowanie problemu, ponieważ maskuje fakt, że niszowe przedmioty ignorowane są na rzecz faworyzowania hitów.

Przeprowadzona analiza opiera się na dwóch etapach: **metryki ewaluacyjne** oceniają trafność rekomendacji w obrębie poszczególnych grup decylowych, a **metryki diagnostyczne** badają dynamikę uczenia się wektorów osadzeń podczas treningu.

6.3.1. Metryki diagnostyczne

L_2 Norm

Pierwszą z metryk jest norma euklidesowa (ang. *L_2 norm*). Mierzy ona „pewność” modelu co do danego węzła. W większości systemów rekomendujących typu *CF* tak jak w modelu *LightGCN*, końcowy wynik rekomendacji dla danej pary użytkownik–przedmiot obliczany jest za pomocą iloczynu skalarnego ich wektorów (jak we wzorze 2.7), a następnie skalar ten przekazywany jest do funkcji sigmoidalnej σ (wzór 5.1.). Jest ona monotonicznie rosnąca, zatem im dłuższy jest wektor (większe wartości wewnątrz wektora), tym łatwiej wygrywa on rankingi. Wyższa średnia jednej grupy od drugiej oznacza, że model mocniej rekomenduje przedmioty z pierwszej grupy.

$$L_2(I_{gr}, t) = \frac{1}{|I_{gr}|} \sum_{i \in I_{gr}} \|\mathbf{e}_i^{(t)}\|_2 = \frac{1}{|I_{gr}|} \sum_{i \in I_{gr}} \sqrt{\sum_{d=0}^{D-1} (\mathbf{e}_{i,d}^{(t)})^2} \quad (6.1)$$

gdzie I_{gr} to zbiór przedmiotów z badanej grupy przedmiotów, a $\mathbf{e}_{i,d}^{(t)}$ to wartość wektora przedmiotu i w epoce treningowej t na pozycji d .

Cosine Drift

Drugim narzędziem jest dryf kosinusowy (ang. *cosine drift*). Metryka ta mierzy „mobilność” (dryf) wektorów, czyli zdolność do uczenia się w trakcie treningu. Obliczana jest ona między tymi samymi wektorami z dwóch różnych epok: wektorem inicjalizowanym losowo przed rozpoczęciem epoki zerowej a wektorem z epoki t . Jeśli podobieństwo kosinusowe wektora w trakcie treningu jest wysokie względem wektora ze stanu początkowego, oznacza to, że wektor otrzymał za mało silnych gradientów do nauki, aby zmienić swoje położenie w przestrzeni względem innych węzłów. Jest to bezpośredni dowód na istnienie problemu *Gradient Starvation*.

$$\begin{aligned} Drift(I_{gr}, t) &= \frac{1}{|I_{gr}|} \sum_{i \in I_{gr}} \frac{\mathbf{e}_i \cdot \mathbf{e}_i^{(t)}}{\|\mathbf{e}_i\|_2 \cdot \|\mathbf{e}_i^{(t)}\|_2} = \\ &= \frac{1}{|I_{gr}|} \sum_{i \in I_{gr}} \frac{\sum_{d=0}^{D-1} \mathbf{e}_{i,d} \mathbf{e}_{i,d}^{(t)}}{\sqrt{\sum_{d=0}^{D-1} \mathbf{e}_{i,d}^2} \sqrt{\sum_{d=0}^{D-1} (\mathbf{e}_{i,d}^{(t)})^2}} \end{aligned} \quad (6.2)$$

gdzie $\mathbf{e}_i$ to wylosowany wektor osadzenia przedmiotu i przed rozpoczęciem procesu uczenia.

6.3.2. Metryki ewaluacyjne

Do analizy skuteczności metod z rozdziału 5. wykorzystano trzy powszechne metryki jakości rankingu: **Recall**, **NDCG** oraz **Precision**, które są obliczane globalnie i grupowo. W tym celu dla zdefiniowanych wcześniej grup decylowych, zmodyfikowano proces ewaluacji, ponieważ w rzeczywistości model rekomenduje przedmioty z każdej grupy, dlatego nie można prosto wygenerować rankingu tylko dla jednej z grup. Zmodyfikowany proces wyłaniania rekomendacji wygląda następująco:

1. Dla każdego użytkownika ze zbioru testowego model wyłania K najlepiej ocenionych przedmiotów na szczeblu globalnym, które nie pojawiły się w zbiorze treningowym.
2. Zbiór testowych interakcji użytkownika u jest filtrowany na poziomie tworzenia macierzy trafień (ang. *relevance matrix*), gdzie aplikowana zostaje maska przedmiotów grupy decylowej gr , co gwarantuje, że przedmioty należą wyłącznie do testowanej grupy.
3. Jeśli po maskowaniu użytkownik nie ma żadnego przedmiotu z badanej grupy gr , nie jest on brany pod uwagę w wynikach.
4. Binarna macierz trafień Rel_{gr} (0 dla przedmiotów spoza grupy gr , a 1 w przeciwnym przypadku) poddawana jest ewaluacji bez zmian w późniejszych krokach do poniższych metryk.

Pierwsze dwie z nich nie biorą pod uwagę kolejności w jakiej rekomendowane są przedmioty, tylko ich trafność.

Recall

Recall (pl. *czułość*) mierzy jaką część ze wszystkich istniejących trafnych przedmiotów udało się umieścić na liście *Top-K* rekomendacji.

$$\text{Recall}@K@gr = \frac{|L_K \cap (G \cap I_{gr})|}{|G \cap I_{gr}|}, \quad (6.3)$$

gdzie L_K to zbiór K najlepszych przedmiotów użytkownika u , G to zbiór prawdziwych informacji (ang. *ground truth*) o jego preferencjach. Jeśli chcemy globalną metrykę, wtedy $I_{gr} = G$.

Precision

Precision (pl. *precyzja*) mierzy jaka część polecanych przedmiotów z listy *Top-K* rekomendacji jest faktycznie dla użytkownika trafiona.

$$\text{Precision@K@gr} = \frac{|L_K \cap (G \cap I_{gr})|}{K} \quad (6.4)$$

NDCG

NDCG - *Normalized Discounted Cumulative Gain* (pl. *znormalizowany zdyskontowany skumulowany zysk*) ocenia jakość danego rankingu rekomendacji biorąc pod uwagę nie tylko trafność, jak również pozycję, na której znajduje się dany przedmiot w liście. Zdefiniowana jest ona jako stosunek *DCG* (*Discounted Cumulative Gain*) listy rankingowej do *IDCG* (*Ideal Discounted Cumulative Gain*), która oznacza ranking, w którym przedmioty są w idealnej kolejności.

DCG oblicza skumulowany zysk danej listy rekomendacji wprowadzając karę (dyskontowanie logarytmiczne) na przedmioty znajdujące się na niższych pozycjach ranking. Zapewnia to, że przedmioty, które są najbardziej istotne muszą znaleźć się na początku listy, aby zachować swój wkład w rekomendacje.

$$\text{DCG@K@gr} = \sum_{i=1}^K \frac{\text{Rel}_{gr}(L_K(i))}{\log_2(i+1)} \quad (6.5)$$

IDCG jest to *DCG* z maksymalnym możliwym wynikiem dla danej rekomendacji. Uzyskuje się go przez posortowanie malejąco przedmiotów według ich trafności (przydatne dla rankingów, w których mamy większy zbiór ocen od $\{0, 1\}$). Następnie tak zmodyfikowana lista rankingowa podstawiana jest do wzoru na *DCG*. Finalny wzór wygląda tak:

$$\text{NDCG@K@gr} = \frac{\text{DCG@K@gr}}{\text{IDCG@K@gr}} \quad (6.6)$$

Dzięki zastosowaniu normalizacji ostateczny wynik *NDCG* mieści się zawsze w przedziale $[0, 1]$, gdzie uzyskanie 1 jest rankingiem doskonałym.

6.4. Wyniki eksperymentów

Celem eksperymentów opisanych w niniejszym rozdziale jest ewaluacja autor-skich oraz literaturowych metod przeciwdziałania zjawisku *Popularity Bias*. Aby poprawnie zinterpretować zgromadzone wyniki, należy na wstępie zdefiniować uniwersalny cel i wzorzec działania wszystkich badanych technik (takich jak modyfikacje funkcji straty czy odpowiednie próbkowanie).

Ich zadaniem nie jest maksymalizacja ogólnej trafności modelu. Sukces każdej z tych metod definiowany jest przez znalezienie optymalnego punktu równowagi, czyli **kompromis** (ang. *trade-off*). Pożądanym rozwiązaniem jest znaczny wzrost miar ewaluacyjnych dla przedmiotów niszowych (Bottom 20%) kosztem redukcji wyników dla elementów najpopularniejszych (Top 20%). Ten celowy transfer skuteczności z „głowy” do „ogona” dystrybucji nieuchronnie pociąga za sobą spadek metryk globalnych. Kluczowe jest jednak to, aby ta degradacja ogólnej skuteczności systemu była kontrolowana i stanowiła racjonalny koszt przywrócenia modelowi zdolności do sprawiedliwej rekomendacji rzadkich elementów.

W kolejnych podrozdziałach przedstawiamy szczegółową analizę wpływu poszczególnych technik mitygacji *Popularity Bias* na jakość rekomendacji oraz dynamikę uczenia reprezentacji. Na początku omawiamy metody *Smoothed BPR* i *IPS*, następnie *FastLightGCN*, próbkowanie grafu inspirowane modelem *PinSage* oraz mechanizmy *edge dropout* i *node dropout*, a na końcu zestawiamy wyniki wariantów hybrydowych łączących kilka technik jednocześnie.

6.4.1. Smoothed BPR

W pierwszej serii eksperymentów badamy wpływ zmiany rozkładu prawdopodobieństwa w algorytmie *BPR*. Poprzez uwzględnienie stopnia węzła oraz parametru wygładzania podczas losowania negatywów, metoda ta ma za zadanie temperować siłę gradientów dla najpopularniejszych przedmiotów grafu. Przetestowaliśmy sześć różnych wartości parametru $\alpha \in \{0.0, 0.25, 0.5, 0.75, 1.0, 1.25\}$. Warto zauważyć, że przypadek $\alpha = 0.0$ stanowi model bazowy (klasyczne losowanie jednostajne), z którym porównywane są pozostałe warianty.

Tabela 6.4 ukazuje, że metoda *SBPR* zachowuje się zgodnie z przewidywaniami. Stopniowe zwiększanie wartości α bezpośrednio koreluje z transferem trafności. Optymalnym kompromisem wydaje się być $\alpha = 0.25$, który zapewnia poprawę metryk dla niszy przy minimalnej degradacji wyników globalnych. Zaś przy skrajnej wartości $\alpha = 1.25$ obserwowany jest przynajmniej pięciokrotny wzrost metryk dla grupy Bottom 20% względem modelu bazowego. Uzasadnienia polepszenia metryk możemy szukać na wykresach *L2 Norm* i *Cosine Drift*, które badają dwie różne właściwości wektorów wspomniane przy ich definiowaniu we wzorach 6.1 i 6.2.







Na zestawieniu wykresów normy L_2 (Rysunek 6.2) przedstawiono wpływ parametru α na wielkość wektorów. Dla modelu bazowego ($\alpha = 0.0$) końcowe wartości długości wektorów dla grupy Bottom 20% (5.81) oraz Top 20% (5.73) są niemal zrównane. Potwierdza to, że przedmioty niszowe nie są w stanie otrzymać odpowiednich aktualizacji wag niezbędnych do silnego zaznaczenia swojej obecności w przestrzeni wektorowej. Jest to spowodowane ich rzadkim występowaniem jako próbki pozytywne w funkcji straty *BPR*, ale za to często jako negatywne. Sprzyja to przegrywaniu w rankingu pomimo podobnej długości wektora.

Parametr α	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
0.0 (Baseline)	0.00797	0.04942	0.33115	0.18199
0.25	0.01249	0.06008	0.31915	0.18140
0.50	0.01862	0.07084	0.29458	0.17280
0.75	0.02662	0.07933	0.26026	0.15951
1.00	0.03425	0.08803	0.22263	0.14505
1.25	0.03947	0.08999	0.19242	0.13191
NDCG@20				
0.0 (Baseline)	0.00262	0.01937	0.23210	0.15377
0.25	0.00417	0.02438	0.22735	0.15387
0.50	0.00656	0.03004	0.20927	0.14507
0.75	0.00983	0.03479	0.18181	0.13121
1.00	0.01352	0.04031	0.15259	0.11550
1.25	0.01624	0.04243	0.12772	0.10169
Precision@20				
0.0 (Baseline)	0.00067	0.00626	0.05649	0.05580
0.25	0.00107	0.00776	0.05475	0.05580
0.50	0.00159	0.00924	0.04968	0.05271
0.75	0.00229	0.01050	0.04243	0.04774
1.00	0.00301	0.01190	0.03496	0.04252
1.25	0.00342	0.01218	0.02892	0.03776







Tabela 6.4: Wpływ parametru wygładzania α w metodzie *Smoothed BPR* na metryki ewaluacyjne (@20).

Zwiększanie parametru wygładzania bezpośrednio wpływa na ten proces. Najbardziej zauważalnym zjawiskiem jest wzrastająca odległość między liniami niszy i hitów na wykresach. Zmiana losowania negatywów na wygładzony rozkład prawdopodobieństwa sprawia, że popularne węzły częściej służą jako punkty odniesienia do kary, co pozwala najrzadszym węzłom na intensywniejszą aktualizację gradientów. Widoczne jest to w szczególności dla $\alpha = 1.25$, gdzie norma L_2 dla grupy Bottom 20% rośnie do wartości 9.00 (wzrost o blisko 55% względem modelu bazowego). Równocześnie przyrost reprezentacji dla grupy Top 20% ulega wyhamowaniu, osiągając na końcu treningu wartość 6.20. Udowadnia to bezpośrednio, że mechanizm *SBPR* kompensuje początkowy niedobór interakcji w zbiorze treningowym, stanowiąc skuteczne narzędzie mitygacji *Popularity Bias*.

Układ wykresów *Cosine Drift* (Rysunek 6.3) dopełnia wnioski wyciągnięte na podstawie normy L_2 , ilustrując wpływ parametru α na mobilność kątową wektorów podczas uczenia. W modelu bazowym ($\alpha = 0.0$) końcowe podobieństwo kosinusowe względem inicjalizacji wynosi około 0.044 dla grupy Bottom 20% oraz 0.061 dla Top 20%. Niskie wartości dla niszy oznaczają, że wektory ulegają silnym rotacjom, jednak

(a) $\alpha = 0.0$ (Model bazowy)(b) $\alpha = 0.25$ (c) $\alpha = 0.50$ (d) $\alpha = 0.75$ (e) $\alpha = 1.00$ (f) $\alpha = 1.25$

Rysunek 6.2: Dynamika normy L_2 wektorów w podziale na grupy decylowe dla różnych wartości parametru α w metodzie *Smoothed BPR*.

(a) $\alpha = 0.0$ (Model bazowy)(b) $\alpha = 0.25$ (c) $\alpha = 0.50$ (d) $\alpha = 0.75$ (e) $\alpha = 1.00$ (f) $\alpha = 1.25$

Rysunek 6.3: Dynamika dryfu kosinusowego wektorów cech w podziale na grupy decylowe dla różnych wartości parametru α w metodzie *Smoothed BPR*.

(jak pokazała norma L_2) pozbawionym odpowiedniej siły ugruntowującej pozycję węzła.

Systematyczny wzrost parametru wygładzania aż do wartości skrajnej ($\alpha = 1.25$) skutkuje widocznym obniżeniem tego wskaźnika do 0.033 dla rzadkich przedmiotów, a dla hitów powiększeniem do 0.064. Biorąc pod uwagę specyfikę tej metryki – gdzie niższa wartość oznacza silniejszą zmianę kierunku względem wektora z epoki zerowej – wynik ten bezpośrednio potwierdza sukces zastosowanej regularyzacji. Wektory niszy otrzymują częstsze aktualizacje gradientowe, co skutecznie redukuje zjawisko *Gradient Starvation*. Zarazem przesunięcie kątowe wektorów hitów ulega spowolnieniu, co dowodzi poprawnego funkcjonowania ich temperatury, co ostatecznie pozwala modelowi częściowo zrównoważyć dynamikę uczenia całego systemu.

6.4.2. Inverse Propensity Scoring

W drugiej serii eksperymentów badamy wpływ ważenia funkcji straty w algorytmie *BPR*. Poprzez przypisywanie wag odwrotnie proporcjonalnych do popularności przedmiotu pozytywnego, metoda ta ma za zadanie wzmacniać siłę gradientów dla najrzadszych przedmiotów grafu. Przetestowaliśmy siedem różnych wartości parametru ograniczającego wpływ estymatora: $C \in \{1, 5, 10, 20, 40, 100, 200\}$. Dla wartości $C = 1$ model nie zmienia istotnie swojego zachowania, dlatego wariant ten traktujemy jako model bazowy, względem którego porównywane są pozostałe konfiguracje.

Analiza danych w Tabeli 6.5 ujawnia dynamikę w dużej mierze zbieżną z wynikami zaprezentowanymi wcześniej dla metody *SBPR*, gdzie kompromisem jest pierwsza testowana wartość ($C = 5$), a najlepszą z nich jest ostatnia ($C = 200$). Chociaż skuteczność *IPS* jest delikatnie osłabiona względem wyników poprzedniej metody, to diametralne różnice pomiędzy oboma mechanizmami ujawniają się dopiero podczas analizy właściwości samej przestrzeni wektorowej, co potwierdzają zestawienia miar L_2 Norm oraz *Cosine Drift*.

Na zestawieniu wykresów normy L_2 (Rysunek 6.4) zaprezentowano wpływ ważenia według popularności przedmiotów pozytywnych. Dla wariantu pozbawionego ważenia ($C = 1.0$), długość reprezentacji dla grupy Bottom 20% i Top 20% jest na tym samym poziomie, co w rozdziale 6.4.1.. Natomiast konsekwentnie podwyższając próg odcięcia do 200, można zaobserwować gwałtowny wzrost wielkości wektorów w skali całego grafu. Dla tej wartości, węzły niszowe budują reprezentacje o normie rzędu 10.94, natomiast węzły popularne szybują aż do poziomu 11.35. Jest to konsekwencją mnożenia różnicy ich rankingów we wzorze 5.3, który wymusza podwyższenie rankingu pozytywu i obniżenie negatywu w celu zbalansowania tego, co robi estymator. Oznacza to, że odpowiednio zmusza on model do nauczenia się, że nisza jest lepsza od hitu.

Układ wykresów *Cosine Drift* (Rysunek 6.5) przedstawia zupełnie inny kierunek







działania niż w metodzie *SBPR*. Co raz to większe wartości parametru skutkują spowolnieniem dryfu kosinusowego z poziomu 0.044 do 0.150 (dla grupy Bottom 20%) oraz z poziomu 0.061 do 0.116 (dla grupy Top 20%). Występuje tutaj odwrócenie ról uczenia się mobilności kątowej wektorów (da się ją zauważyć na przestrzeni wykresów), gdzie nisza uczy się wolniej, a hity szybciej. L_2 Norm pokazuje eksplozję długości wektorów, a *Cosine Drift* odkrywa, że wektory zamiast zmieniać swoją lokalizację w przestrzeni, sztywnieją i wydłużają się mniej więcej tym samym kierunkiem.

Parametr C	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
1.0 (Baseline)	0.00791	0.04887	0.33130	0.18256
5.0	0.01648	0.06943	0.30059	0.17668
10.0	0.01976	0.07355	0.28112	0.17061
20.0	0.02432	0.07680	0.26095	0.16717
40.0	0.02655	0.07917	0.24350	0.16447
100.0	0.03193	0.08402	0.22348	0.16245
200.0	0.03842	0.08406	0.21851	0.16269
NDCG@20				
1.0 (Baseline)	0.00262	0.01941	0.23176	0.15401
5.0	0.00566	0.02933	0.21507	0.14920
10.0	0.00682	0.03214	0.20016	0.14419
20.0	0.00838	0.03454	0.18408	0.14114
40.0	0.00931	0.03693	0.16939	0.13919
100.0	0.01170	0.04086	0.15325	0.13765
200.0	0.01445	0.04128	0.14913	0.13780
Precision@20				
1.0 (Baseline)	0.00068	0.00620	0.05644	0.05592
5.0	0.00139	0.00864	0.05154	0.05376
10.0	0.00165	0.00916	0.04833	0.05161
20.0	0.00200	0.00952	0.04485	0.05013
40.0	0.00219	0.00994	0.04180	0.04914
100.0	0.00266	0.01074	0.03841	0.04848
200.0	0.00320	0.01079	0.03755	0.04864







Tabela 6.5: Wpływ progu odcięcia C w metodzie *Inverse Propensity Scoring* na metryki ewaluacyjne (@20).

6.4.3. FastLightGCN

Kolejną analizowaną w pracy architekturą jest *FastLightGCN*, czyli autorska adaptacja stochastycznego modelu *FastGCN*. Wykorzystuje ona warstwowe próbkowanie metodą *Monte Carlo*, które nie tylko ogranicza koszt obliczeniowy fazy propagacji, ale przede wszystkim drastycznie zmienia dynamikę przepływu informacji

(a) $C = 1$ (Model bazowy)(b) $C = 5$ (c) $C = 10$ (d) $C = 40$ (e) $C = 100$ (f) $C = 200$

Rysunek 6.4: Dynamika normy L_2 wektorów w podziale na grupy decylowe dla różnych wartości parametru C w metodzie *Inverse Propensity Scoring*. Pominęto wykres z wartością $C = 20$, ponieważ jest on bardzo podobny do wykresów wartości $C \in \{10, 40\}$.

(a) $C = 1$ (Model bazowy)(b) $C = 5$ (c) $C = 10$ (d) $C = 40$ (e) $C = 100$ (f) $C = 200$

Rysunek 6.5: Dynamika dryfu kosinusowego wektorów cech w podziale na grupy decylowe dla różnych wartości parametru C w metodzie *Inverse Propensity Scoring*. Pominięto wykres z wartością $C = 20$, ponieważ jest on bardzo podobny do wykresów wartości $C \in \{10, 40\}$.

w grafie użytkownik–przedmiot. Z perspektywy niniejszej pracy kluczowe jest to, że tego typu strukturalny *dropout* ingeruje w proces uczenia popularnych węzłów. Redukując pełną, deterministyczną agregację, model może bezpośrednio przeciwdziałać propagacji *Popularity Bias* oraz osłabiać wpływ zjawiska *Structure Noise*. Analiza działania modelu zostanie przeprowadzona w następującej kolejności:


1. wpływ głębokości modelu oraz szerokości warstw na jakość rekomendacji w obrębie grup popularności,
2. wpływ wymuszenia unikalności próbkowanych węzłów (**unique**) na stabilność estymatora,
3. wpływ szerokości warstwy inicjalizującej tj. *batch size*,
4. porównanie klasycznego *Importance Sampling* (*IS*) z jego wygładzoną wersją, czyli *Smoothed Importance Sampling* (*SIS*).

Głębokość i szerokość modelu


Konfiguracja	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
[32]	0.00273	0.01503	0.22506	0.11783
[32, 32, 32, 32]	0.00254	0.01027	0.18798	0.10115
[2048]	0.00446	0.02614	0.28896	0.15172
[2048, 2048, 2048, 2048]	0.01055	0.03810	0.28859	0.15842
NDCG@20				
[32]	0.00097	0.00651	0.14362	0.09674
[32, 32, 32, 32]	0.00101	0.00458	0.11767	0.08305
[2048]	0.00163	0.01067	0.18935	0.12345
[2048, 2048, 2048, 2048]	0.00411	0.01659	0.18998	0.12872
Precision@20				
[32]	0.00027	0.00201	0.03781	0.03610
[32, 32, 32, 32]	0.00024	0.00138	0.03306	0.03139
[2048]	0.00043	0.00330	0.04704	0.04511
[2048, 2048, 2048, 2048]	0.00095	0.00481	0.04978	0.04875

Tabela 6.6: Wpływ szerokości i głębokości propagacji na metryki ewaluacyjne modelu *FastLightGCN* z *batch size* = 2048.


Realizując pierwszy punkt planu badawczego, przebadaliśmy cztery warianty głębokości propagacji (od 1 do 4) w zestawieniu z siedmioma różnymi rozmiarami warstwy próbkowanej $t_l \in \{2^5, \dots, 2^{11}\}$. Należy zaznaczyć, że wielkość pierwszej




(a) [32]



(b) [32, 32, 32, 32]




(c) [2048]




(d) [2048, 2048, 2048, 2048]


Rysunek 6.6: Dynamika normy L_2 wektorów w podziale na grupy decylowe dla różnej liczby warstw i ich rozmiarów w modelu *FastLightGCN*




(a) [32]



(b) [32, 32, 32, 32]



(c) [2048]



(d) [2048, 2048, 2048, 2048]

Rysunek 6.7: Dynamika dryfu kosinusowego wektorów cech w podziale na grupy decylowe dla różnej liczby warstw i ich rozmiarów w modelu *FastLightGCN*

warstwy w próbkowanych podgrafach dwudzielnych jest ściśle zależna od parametru *batch size*, którego wpływ zostanie omówiony w dalszej części pracy. Dla potrzeb niniejszych eksperymentów przyjęliśmy domyślną wartość tego parametru z modelu *LightGCN*, wynoszącą 2048.

Bez straty ogólności, w analizie zestawiliśmy ze sobą skrajne szerokości próbkowania (32 i 2048) dla głębokości 1 oraz 4, ponieważ dla wartości pośrednich obserwowane są spójne i ciągłe trendy. Analiza zaprezentowanych wyników ujawnia, że sam *FastLightGCN* nie dorównuje modelowi bazowemu zarówno na tle globalnym jak i grup decylowych – różnica powinna zostać zniwelowana w rozdziale 6.4.5., poświęconym połączonym metodom mitygacji. Niezależnie od tego pozornego spadku trafności, poddamy analizie mechanikę tego modelu, aby zweryfikować, w jakim stopniu stochastyczna propagacja wpływa na *Popularity Bias*.

Przyczyną powyższego zachowania jest fundamentalne ograniczenie wielowarstwowego próbkowania węzłów w rzadkich grafach. Z danych w Tabeli 6.6 wynika, że dla wąskich wariantów próbkowania (np. szerokość 32) zwiększenie głębokości sieci prowadzi do wyraźnej degradacji jakości rekomendacji, co uderza przede wszystkim w grupy Middle 60% i Top 20%, przy jedynie śladowej zmianie wyników dla grupy Bottom 20%. Zjawisko to można interpretować jako skutek narastającego błędu aproksymacji estymatora *Monte Carlo*. We wzorze 5.9 każda warstwa propagacji jest opisana przez osobną macierz przejścia, zawierającą odpowiednio przeskalowane prawdopodobieństwa próbkowania. Kaskadowe mnożenie tych macierzy przy małych rozmiarach próbki powoduje szybką akumulację szumu i stopniowe rozmywanie sygnału kolaboratywnego. Co ciekawe, efekt ten zanika dla najszerszego wariantu (2048), gdzie aproksymacja jest na tyle dokładna, że większa głębokość znacząco poprawia wynik.

Negatywny wpływ propagacji szumu można bezpośrednio zaobserwować na wykresie 8.2. Pokazuje on, że głębsze modele, w których zastosowaliśmy wąskie próbkowanie, utrzymują wyższe i bardzo niestabilne wartości funkcji straty. Wskazuje to na znaczną trudność optymalizacji oraz wysoką podatność procesu uczenia na ogromną wariancję wprowadzaną przez rygorystyczne ograniczenie liczby losowanych sąsiadów.

Szczegółowy wgląd w ten błąd dają metryki diagnostyczne pozwalające na interpretację reprezentacji wektorów. Analizując ogólne wartości L_2 Norm (Rysunek 6.6) oraz *Cosine Drift* (Rysunek 6.7), można wyraźnie dostrzec, jak rozmiar warstwy determinuje stabilność reprezentacji w całej przestrzeni osadzeń. W przypadkach, gdy decydujemy się na szerokie próbkowanie połączone z większą głębokością ([2048, 2048, 2048, 2048]), wektory uczą się stabilnie: ich norma L_2 naturalnie rośnie, a dryf pozostaje wysoki, co pozwala uformować spójną przestrzeń. Z kolei w wariantach opartych na wąskim próbkowaniu ([32, 32, 32, 32]) zjawisko to ulega drastycznemu odwróceniu. Ograniczenie liczby losowanych sąsiadów sprawia, że wektory wpadają w słaby dryf, a ich długość zostaje silnie zredukowana.

Powyższy obraz pozwala sformułować spójny wniosek: optymalizacja głębokiej

architektury z mechanizmem losowym ma sens tylko wtedy, gdy szerokość próbkowania gwarantuje precyzyjną aproksymację sąsiedztwa. W przeciwnym razie stochastyczność kaskadowych warstw całkowicie niszczy strukturę przestrzeni osadzeń, przez co przy wąskim próbkowaniu optymalnym i najbezpieczniejszym wyborem projektowym pozostaje model płytki, który naturalnie buforuje akumulację wariancji błędu.

Parametr unique

Konfiguracja	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
[2048]	0.00446	0.02614	0.28896	0.15172
[2048]-unique	0.00460	0.02543	0.28609	0.15044
[2048, 2048, 2048, 2048]	0.01055	0.03810	0.28859	0.15842
[2048, 2048, 2048, 2048]-unique	0.00929	0.02548	0.24600	0.13632
NDCG@20				
[2048]	0.00163	0.01067	0.18935	0.12345
[2048]-unique	0.00165	0.01038	0.18552	0.12099
[2048, 2048, 2048, 2048]	0.00411	0.01659	0.18998	0.12872
[2048, 2048, 2048, 2048]-unique	0.00404	0.01187	0.13477	0.09317
Precision@20				
[2048]	0.00043	0.00330	0.04704	0.04511
[2048]-unique	0.00042	0.00320	0.04618	0.04435
[2048, 2048, 2048, 2048]	0.00095	0.00481	0.04978	0.04875
[2048, 2048, 2048, 2048]-unique	0.00087	0.00312	0.04080	0.03944

Tabela 6.7: Wpływ wymuszenia unikalności próbkowanych węzłów na metryki ewaluacyjne modelu *FastLightGCN* dla konfiguracji opartych na szerokości warstwy 2048 i *batch size* równym 2048.

W dalszej części analizy ograniczamy się do konfiguracji [2048, 2048, 2048, 2048], aby zachować przejrzystość prezentacji wyników, a zarazem skupić się na wariancie najbardziej reprezentatywnym dla wcześniej zaobserwowanych tendencji.

Przechodząc do analizy wariantu **unique**, opisanego w rozdziale 5.3.4., zestawienie wyników uwydatnia jego ścisłą zależność od głębokości propagacji. Dla pojedynczej warstwy mechanizm ten naturalnie nie wpływa na metryki, ponieważ próbkowanie sąsiadów dla zadanego węzła i tak realizujemy bez zwracania. Skutki działania deduplikacji ujawniają się dopiero w architekturach głębszych.

Utrzymywanie globalnego zbioru wylosowanych wierzchołków $\mathcal{V}$ dla wielu warstw drastycznie degradowe jakość modelu, co obrazuje załamanie się globalnych metryk.

Wynika to z faktu, że ściśle blokowanie ponownego losowania węzłów w kolejnych krokach propagacji pozbawia podgraf jego gęsto połączonego charakteru. Ścieżki przepływu sygnału przestają się naturalnie przecinać, a struktura samplowanego grafu zaczyna przypominać zbiór rozłącznych ścieżek – swoisty las drzew, których korzeniami są węzły z początkowej paczki. Tak drastyczne ograniczenie przepływu informacji niszczy aproksymację sąsiedztwa i dowodzi, że narzucanie globalnej unikalności węzłów w głębokim próbkowaniu przynosi więcej szkody niż pożytku.

Warstwa inicjalizująca (*batch size*)

Batch size	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
2048	0.01055	0.03810	0.28859	0.15842
1024	0.01227	0.04105	0.29148	0.16203
512	0.01522	0.04624	0.29439	0.16673
NDCG@20				
2048	0.00411	0.01659	0.18998	0.12872
1024	0.00482	0.01816	0.19334	0.13209
512	0.00606	0.01997	0.19489	0.13543
Precision@20				
2048	0.00095	0.00481	0.04978	0.04875
1024	0.00110	0.00519	0.05072	0.05003
512	0.00132	0.00578	0.05135	0.05136

Tabela 6.8: Wpływ parametru *batch size* na metryki ewaluacyjne modelu *FastLightGCN* dla konfiguracji [2048, 2048, 2048, 2048].

Kolejnym badanym hiperparametrem jest *batch size*, który wpływa nie tylko na liczbę węzłów wejściowych w paczce, ale pośrednio również na rozmiar pierwszej warstwy w próbkowanym grafie dwudzielnym. Parametr ten ma kluczowe znaczenie dla skali uczenia stochastycznego: zmniejszanie wielkości paczki oznacza, że w trakcie jednej epoki model generuje i przetwarza więcej podgrafów, co prowadzi do znacznie częstszych aktualizacji reprezentacji za pomocą gradientu.

Zestawienie wyników w Tabeli 6.8 ujawnia wysoce korzystny wpływ tego mechanizmu na działanie modelu. W przeciwieństwie do zjawisk obserwowanych w klasycznych architekturach, zmniejszanie wartości *batch size* (od 2048 do 512) prowadzi do systematycznej poprawy globalnej jakości rekomendacji. Szczególną uwagę zwraca zachowanie poszczególnych grup popularności: podczas gdy metryki dla grupy Top 20% poprawiają się jedynie marginalnie, wyniki grupy Bottom 20% odnotowują skok o blisko 50%. Sugeruje to, że mniejsze rozmiary paczki, prowadzące do częstszych

aktualizacji skutecznie przełamują dominację najpopularniejszych przedmiotów, drastycznie zwiększając ekspozycję obiektów niszowych bez jednoczesnej degradacji elementów z czołówki.







Powyższy wniosek znajduje doskonałe odzwierciedlenie w analizie geometrii przestrzeni osadzeń, zaprezentowanej na Rysunku 6.8. Wraz ze zmniejszaniem *batch size* obserwujemy wyraźny wzrost normy L_2 we wszystkich grupach popularności. Co jednak kluczowe dla zjawiska *Popularity Bias*, częstsze aktualizacje prowadzą do zatarcia dysproporcji w długościach wektorów. Dla dużego rozmiaru paczki (2048) długość wektorów Top 20% (8.19) znacznie górowała nad grupą Bottom 20% (6.97). Zmniejszenie paczki do 512 sprawia, że wektory niszowe rosną na tyle dynamicznie (9.27), że niemal zrównują się z hitami (9.59). Oznacza to fizyczną zrównanie siły oddziaływania wektorów w przestrzeni.

Jednocześnie analiza *Cosine Drift* wskazuje, że mniejsze paczki stabilizują kierunek uczenia. Choć grupa Top 20% niezmiennie wykazuje najsilniejsze odchylenie kątowe względem inicjalizacji, to bezwzględna wartość tego dryfu dla wszystkich grup systematycznie maleje wraz ze zmniejszaniem *batch size*. Interpretujemy to zjawisko jako bezpośredni skutek drastycznej poprawy jakości aproksymacji *Monte Carlo* w relacji do rozmiaru paczki. Przy zmniejszeniu *batch size* do 512 i zachowaniu stałej szerokości próbkowania na poziomie 2048, pierwsza warstwa propagacji jest czterokrotnie większa od warstwy wejściowej. W rezultacie na każdy węzeł z paczki przypada proporcjonalnie znacznie szersze i bogatsze w informacje sąsiedztwo niż wariancie bazowym (2048 do 2048). Ta zwiększona precyzja estymatora, połączona z częstszymi aktualizacjami gradientu w ramach epoki, skutecznie stabilizuje trajektorię osadzeń. Zmniejszenie rozmiaru paczki okazuje się zatem nie tylko działaniem ukierunkowanym na wyrównanie siły wektorów i mitygację *Popularity Bias*, ale również fundamentalnym zabiegiem poprawiającym jakość stochastycznej propagacji w architekturze *FastLightGCN*.

Wygładzone prawdopodobieństwo *SIS*

Ostatnim badanym elementem architektury *FastLightGCN* jest mechanizm *Smoothed Importance Sampling (SIS)*. W naszych eksperymentach przeanalizowaliśmy wpływ wygładzania dystrybucji na proces uczenia, przyjmując za punkt wyjścia próbkowanie liniowo proporcjonalne do stopnia węzła ($\alpha = 1.0$), a następnie systematycznie redukując ten parametr aż do osiągnięcia rozkładu jednorodnego ($\alpha = 0.0$).

Kluczowym wnioskiem z analizy jest to, że zastosowanie próbkowania faworyzującego wierzchołki o wysokim stopniu odnosi swoisty sukces w kontekście celowego uderzenia w zjawisko *Popularity Bias*. Zestawienie wyników ukazuje, że wariant $\alpha = 1.0$ drastycznie i selektywnie obniża jakość rekomendacji dla obiektów najpopularniejszych (grupa Top 20%) oraz dla elementów ze środka rozkładu (Middle 60%). Jednocześnie metryki dla grupy z długiego ogona (Bottom 20%) utrzymują się

(a) L_2 Norm dla $batch\ size = 2048$ (b) $Cosine\ Drift$ dla $batch\ size = 2048$ (c) L_2 Norm dla $batch\ size = 1024$ (d) $Cosine\ Drift$ dla $batch\ size = 1024$ (e) L_2 Norm dla $batch\ size = 512$ (f) $Cosine\ Drift$ dla $batch\ size = 512$

Rysunek 6.8: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego ($Cosine\ Drift$) wektorów przedmiotów w grupach popularności dla różnych wartości parametru $batch\ size$ w modelu *FastLightGCN*.

Wartość SIS	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
Brak	0.01045	0.03744	0.28720	0.15775
0.0	0.01009	0.03412	0.28138	0.15372
0.25	0.00860	0.03057	0.27542	0.14911
0.5	0.00879	0.02702	0.26786	0.14456
0.75	0.00872	0.02328	0.25665	0.13809
1.0	0.00877	0.02162	0.24724	0.13326
NDCG@20				
Brak	0.00407	0.01626	0.18951	0.12836
0.0	0.00392	0.01508	0.18456	0.12461
0.25	0.00358	0.01362	0.17845	0.12057
0.5	0.00349	0.01216	0.17111	0.11536
0.75	0.00340	0.01052	0.16205	0.10901
1.0	0.00361	0.00987	0.15592	0.10478
Precision@20				
Brak	0.00097	0.00478	0.04976	0.04876
0.0	0.00090	0.00448	0.04910	0.04795
0.25	0.00081	0.00403	0.04831	0.04677
0.5	0.00084	0.00354	0.04707	0.04525
0.75	0.00084	0.00308	0.04521	0.04319
1.0	0.00086	0.00288	0.04361	0.04164

Tabela 6.9: Wpływ parametru *SIS* na metryki ewaluacyjne modelu *FastLightGCN* dla konfiguracji [2048, 2048, 2048, 2048] z *batch size* równym 2048.

na stabilnym poziomie. To agresywne tłumienie hitów wprowadza jednak ogromną wariancję do estymatora, co bezpośrednio przekłada się na skrajnie zaszumiony i niestabilny przebieg funkcji straty, zaprezentowany na Rysunku 8.2. Systematyczne wygładzanie rozkładu (zmniejszanie parametru α w kierunku 0.0) skutecznie eliminuje ten szum gradientowy, prowadząc do wyraźnego odzyskania globalnej jakości metryk oraz ustabilizowania optymalizacji.

Selektywne uderzenie w hity ma swoje bezpośrednie odzwierciedlenie w geometrii przestrzeni osadzeń, co prezentujemy na Rysunku 6.9, przedstawiającym przebieg metryk L_2 Norm oraz *Cosine Drift*. Przy braku wygładzania ($\alpha = 1.0$) wektory wszystkich grup odnotowują podwyższone, chaotyczne błędzenie kierunkowe – *Cosine Drift* osiąga wartość 0.140 dla Top 20% i 0.108 dla Bottom 20%. Dodatkowo, norma L_2 w grupie Top 20% zostaje widocznie stłumiona do poziomu 7.84, a dla Bottom 20% spada do 6.70. Zastosowanie równomiernego próbkowania ($\alpha = 0.0$) uwalnia potencjał reprezentacji: pozwala wektorom z ogona na silniejszy wzrost (ich norma L_2 rośnie do 7.19) oraz stabilizuje trajektorię we wszystkich badanych decylach (spadek *Cosine Drift* do 0.129 dla hitów i 0.100 dla nisy).

Z perspektywy mechaniki propagacji, losowanie stochastyczne z progiem $\alpha = 1.0$ w sposób nienaturalny zalewa próbkowane podgrafy hitami. Najpopularniejsze elementy pojawiają się w sąsiedztwie niemal każdego węzła, ich wektory są uśredniane ze zbyt dużą liczbą niespokrewnionych obiektów, co powoduje zatarcie ich unikalnego sygnału (ang. *oversmoothing*). W praktyce działa to jak destrukcyjny mechanizm tłumiący *Popularity Bias*. Eksperyment udowadnia jednak kluczową rolę mechanizmu wygładzania. Płynne redukowanie wpływu stopnia węzła za pomocą parametru α zapobiega opisanemu przesyleniu i uspokaja dynamikę optymalizacji. Stanowi to w *FastLightGCN* potężne narzędzie do strukturalnej regularyzacji, pozwalające na świadome modelowanie przestrzeni osadzeń bez narażania modelu na skrajną wariancję estymatora.

6.4.4. Błądzenie losowe PinSage’a i dropouty

Ostatnią grupą metod, którą przeanalizowano, są różnego rodzaju techniki dropoutu strukturalnego. Pierwszą z nich jest metoda próbkowania za pomocą krótkich ścieżek błądzenia losowego inspirowana modelem *PinSage*, która dynamicznie zmienia sąsiedztwo każdego z węzłów. Z perspektywy optymalizacyjnej mechanizm ten pełni funkcję zaawansowanego, strukturalnego dropoutu. Drugim i trzecim badanym rozwiązaniem są odpowiednio *edge dropout*, polegający na losowym usuwaniu części krawędzi w trakcie propagacji oraz *node dropout*, który eliminuje całe węzły wraz z ich incydentnymi krawędziami. Dzięki zastosowaniu powyższych mechanizmów model nie uczy się sztywnego polegania na konkretnych, dominujących elementach. Odfiltrowanie przypadkowych połączeń ogranicza szum strukturalny oraz znacznie osłabia faworyzowanie najpopularniejszych przedmiotów.







Aby obiektywnie zbadać skuteczność próbkowania grafu metodą *PinSage*, proces badawczy podzielono na cztery niezależne, kluczowe części sterujące budową i wykorzystaniem grafu (w nawiasach umieszczono nazwy testowanych zmiennych):

- częstotliwość przebudowy grafu (*pin_sampling*).
- rozmiar sąsiedztwa (*pin_top_k*),
- liczba ścieżek (*pin_n_traces*),
- długość ścieżek (*pin_n_hops*),

Wszystkie powyższe testy przeprowadzono dla modelu bazowego o liczbie warstw $L = 4$.

Częstotliwość przebudowy grafu

Pierwszym badanym parametrem jest częstotliwość stochastycznej przebudowy podgrafu (*pin_sampling*), zdefiniowana jako liczba epok X , po których następuje

(a) L_2 Norm dla $SIS = 1.0$ (b) $Cosine$ Drift dla $SIS = 1.0$ (c) L_2 Norm dla $SIS = 0.5$ (d) $Cosine$ Drift dla $SIS = 0.5$ (e) L_2 Norm dla $SIS = 0.0$ (f) $Cosine$ Drift dla $SIS = 0.0$

Rysunek 6.9: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego ($Cosine$ Drift) wektorów przedmiotów w grupach popularności dla wybranych wartości parametru SIS w modelu *FastLightGCN*.

ponowne losowanie ścieżek i generowanie nowej macierzy sąsiedztwa. Mechanizm ten determinuje, jak długo model eksploatuje daną topologię w procesie treningowym. Analizując jego wpływ na zjawisko *Popularity Bias*, testowaliśmy go dla wartości $X \in \{1, 5, 20, 100, 1000\}$ przy trzech różnych wariantach maksymalnego rozmiaru sąsiedztwa $T \in \{25, 50, 75\}$, stałej liczbie sąsiadów ($K = 12$) oraz długości ścieżek ($H = 4$). Poniżej przyglądamy się modelom z najlepszymi wynikami z parametrem T równym 75.

Parametr X	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
1000	0.01758	0.05701	0.31758	0.18164
100	0.01662	0.05675	0.31982	0.18213
20	0.01762	0.05656	0.31632	0.18222
5	0.01778	0.05637	0.31526	0.18082
1	0.01695	0.05724	0.31602	0.18121
Baseline	0.00764	0.04903	0.33142	0.18194
NDCG@20				
1000	0.00609	0.02316	0.22420	0.15249
100	0.00566	0.02328	0.22552	0.15308
20	0.00608	0.02321	0.22410	0.15266
5	0.00611	0.02304	0.22303	0.15175
1	0.00580	0.02343	0.22225	0.15181
Baseline	0.00255	0.01916	0.23263	0.15381
Precision@20				
1000	0.00147	0.00721	0.05446	0.05537
100	0.00142	0.00723	0.05474	0.05555
20	0.00150	0.00720	0.05429	0.05536
5	0.00149	0.00709	0.05408	0.05522
1	0.00145	0.00726	0.05387	0.05506
Baseline	0.00068	0.00619	0.05655	0.05583

Tabela 6.10: Wpływ parametru X na metryki ewaluacyjne modelu bazowego dla parametrów $T = 75$, $K = 12$ i $H = 4$.

Analiza danych ukazuje, że wyniki metryk dla każdej wartości są do siebie bardzo zbliżone. Dowodzi to dużej odporności na wariancję, ponieważ generowane grafy w znacznej mierze pokrywają się topologicznie, zapewniając optymalizatorowi stabilny i powtarzalny przepływ gradientu. Jednakże, w momencie przebudowy grafu widać, że im model dłużej się uczy danej topologii tym większy jest spadek metryk, który później stopniowo odbudowuje. Rysunek 8.1 przedstawia tę sytuację.

Zbieżność tych wyników pozwala stwierdzić, że dobór parametru X dyktowany jest przede wszystkim kosztem obliczeniowym. Aplikowanie tego mechanizmu w każdej epoce ($X = 1$), wzorem klasycznego dropoutu, przy swoim ogromnym obciążeniu czasu i energii, nie przynosi racjonalnego zysku w trafności predykcji. Odświeżanie

macierzy co 20 epok stanowi optymalny punkt kompromisu, który z powodzeniem osłabia zjawisko *Popularity Bias*, oferując jednocześnie najlepszą wartość *Precision* dla niszy wśród testowanych parametrów.

W następnych częściach analizy podobnie jak w rozdziale 6.4.3., ograniczamy się do jednej konfiguracji, którą będziemy modyfikować na rzecz danego parametru. Jest nią $20 - 4 - 75 - 12$, co odpowiada układowi $X - H - T - K$.

Rozmiar sąsiedztwa

Parametr K	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
20	0.01305	0.05271	0.32324	0.18117
16	0.01522	0.05514	0.32182	0.18177
12	0.01762	0.05656	0.31632	0.18222
10	0.01921	0.05780	0.31548	0.18048
8	0.02022	0.05745	0.31074	0.17823
6	0.01784	0.05628	0.30281	0.17460
4	0.01620	0.05458	0.28885	0.16750
Baseline	0.00764	0.04903	0.33142	0.18194
NDCG@20				
20	0.00442	0.02127	0.22574	0.15159
16	0.00522	0.02236	0.22583	0.15260
12	0.00608	0.02321	0.22410	0.15266
10	0.00681	0.02352	0.22322	0.15185
8	0.00700	0.02325	0.22015	0.15010
6	0.00630	0.02351	0.21482	0.14681
4	0.00576	0.02296	0.20387	0.14028
Baseline	0.00255	0.01916	0.23263	0.15381
Precision@20				
20	0.00111	0.00669	0.05507	0.05528
16	0.00129	0.00701	0.05488	0.05545
12	0.00150	0.00720	0.05429	0.05536
10	0.00162	0.00737	0.05390	0.05492
8	0.00169	0.00724	0.05306	0.05408
6	0.00152	0.00709	0.05180	0.05286
4	0.00143	0.00679	0.04919	0.05029
Baseline	0.00068	0.00619	0.05655	0.05583

Tabela 6.11: Wpływ parametru K na metryki ewaluacyjne modelu bazowego dla parametrów $X = 20$, $H = 4$ i $T = 75$.

Drugim badanym aspektem jest wpływ redukcji sąsiedztwa węzła, definiowanej przez parametr pin_top_k (krócej K). Po zliczeniu częstotliwości odwiedzin po-

szczególnych wierzchołków w trakcie błędzenia losowego, mechanizm ten zachowuje jedynie najczęściej odwiedzanych K węzłów, odrzucając pozostałe krawędzie. Działa to rygorystycznie, zmuszając model do kompresji informacji strukturalnej. Eksperymenty przeprowadzono dla wartości $K \in \{20, 16, 12, 10, 8, 6, 4\}$.

Analiza zgromadzonych wyników (Tabela 6.11) potwierdza, że badany parametr jest kluczowym mechanizmem regularyzacyjnym. Przy szerokim sąsiedztwie ($K = 20$), wygenerowany podgraf zachowuje na tyle dużą przepustowość, że umożliwia silną propagację sygnału przez hity. Model bardzo szybko powraca do ich faworyzowania, dławiąc jednocześnie przyrost skuteczności dla niszy.

Sytuacja ulega poprawie po zredukowaniu liczby sąsiadów do $K = 8$. Ustalenie to gwarantuje optymalny balans mitygacji *Popularity Bias*. Przeprowadzenie ukierunkowanego, strukturalnego dropoutu odcina nadmiarowe, szumowe krawędzie wokół hubów, co bezpośrednio przekłada się na drastyczny wzrost skuteczności predykcji w grupie *Bottom 20%* względem modelu bazowego, a węzły popularne tracą swoją dotychczasową pozycję.

Analiza L_2 Norm i *Cosine Drift* (Rysunek 8.3) ukazuje, że ten mechanizm skutecznie dekompresuje osadzenia popularnych przedmiotów, jednak wektory z grupy niszowej również ulegają skróceniu. Dzieje się to dlatego, że zmniejszając liczbę sąsiadów, ograniczamy przepływ informacji, pozbawiając strukturę cennych sygnałów kolaboratywnych. W skrajnych przypadkach (np. dla wartości $K = 4$) prowadzi to do spadku każdej z metryk.

Liczba ścieżek

Trzecim weryfikowanym parametrem jest liczba ścieżek (*pin_n_traces*, dalej oznaczana jako T) inicjowanych z każdego węzła. Parametr ten decyduje o sile eksploatacji lokalnej topologii, wpływając na precyzję estymacji sąsiedztwa. Eksperymenty przeprowadzono dla $T \in \{25, 50, 75, 100, 125, 150\}$.

Dane obrazują, że skuteczność modelu rośnie współmiernie do wielkości próby. Wynika to z faktu, że przy zbyt małej liczbie ścieżek (np. $T = 25$) wyselekcjonowane sąsiedztwo jest wysoce niestabilne. Zliczanie odwiedzin węzłów obarczone jest wtedy dużym błędem statystycznym, przez co model uczy się na zaszumionych relacjach, gubiąc istotny sygnał kolaboratywny. Wraz ze zwiększaniem parametru T , podgraf zaczyna się stabilizować. Skutkuje to poprawą metryk globalnych z tendencją do przejmowania kontroli nad systemem przez grupę *Top 20%*. Grupa *Bottom 20%* również zyskuje, jednak na poziomie $T = 75$ jej skuteczność ulega stabilizacji.

Zjawisko to znajduje odzwierciedlenie w analizie przestrzeni wektorowej (Rysunek 8.4). Zgromadzone dane ukazują zależność odwrotnie proporcjonalną względem parametru T : podczas gdy predykcja modelu rośnie, normy L_2 Norm wszystkich węzłów maleją, a wskaźnik *Cosine Drift* ulega powolnemu obniżeniu. Wskazuje to,

Parametr T	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
150	0.01765	0.05665	0.32083	0.18272
125	0.01727	0.05742	0.31974	0.18251
100	0.01732	0.05647	0.31839	0.18204
75	0.01762	0.05656	0.31632	0.18222
50	0.01661	0.05644	0.31591	0.18051
25	0.01568	0.05306	0.31088	0.17588
Baseline	0.00764	0.04903	0.33142	0.18194
NDCG@20				
150	0.00598	0.02314	0.22636	0.15340
125	0.00602	0.02346	0.22482	0.15312
100	0.00587	0.02287	0.22479	0.15258
75	0.00608	0.02321	0.22410	0.15266
50	0.00579	0.02320	0.22267	0.15142
25	0.00551	0.02195	0.21849	0.14755
Baseline	0.00255	0.01916	0.23263	0.15381
Precision@20				
150	0.00147	0.00718	0.05502	0.05566
125	0.00149	0.00730	0.05479	0.05562
100	0.00146	0.00717	0.05472	0.05554
75	0.00150	0.00720	0.05429	0.05536
50	0.00143	0.00724	0.05404	0.05492
25	0.00137	0.00678	0.05264	0.05330
Baseline	0.00068	0.00619	0.05655	0.05583

Tabela 6.12: Wpływ parametru T na metryki ewaluacyjne modelu bazowego dla parametrów $X = 20$, $H = 4$ i $K = 12$.

że duże wartości normy L_2 przy małej próbie losowej są sztucznie zawyżane przez błąd statystyczny błędzenia losowego. Gęstsze próbkowanie filtruje ten szum. Dalsze zwiększanie parametru ($T \geq 100$) minimalizuje błąd na tyle, że podgraf zbiega do struktury deterministycznej pełnego grafu, co prowadzi do nawrotu zjawiska *Popularity Bias*.

Długość ścieżek

Ostatnim badanym parametrem dla próbkowania grafów modelu *PinSage* jest długość pojedynczej ścieżki (*pin_n_hops*, czyli H). Zdefiniowanie tego parametru odpowiada ukształtowaniu tzw. pola recepcji (ang. *receptive field*) dla każdego wierzchołka, czyli promienia strukturalnego, z którego węzeł jest w stanie agregować sygnał kolaboratywny podczas propagacji. Eksperymenty przeprowadzono dla $H \in \{1, 2, 4, 6\}$.

Parametr H	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
6	0.01541	0.05722	0.31691	0.18071
4	0.01762	0.05656	0.31632	0.18222
2	0.01731	0.05741	0.31833	0.18135
1	0.01068	0.05899	0.31722	0.18114
Baseline	0.00764	0.04903	0.33142	0.18194
NDCG@20				
6	0.00536	0.02292	0.22252	0.15116
4	0.00608	0.02321	0.22410	0.15266
2	0.00603	0.02347	0.22569	0.15310
1	0.00353	0.02456	0.22524	0.15328
Baseline	0.00255	0.01916	0.23263	0.15381
Precision@20				
6	0.00136	0.00716	0.05422	0.05495
4	0.00150	0.00720	0.05429	0.05536
2	0.00146	0.00727	0.05465	0.05543
1	0.00089	0.00755	0.05447	0.05543
Baseline	0.00068	0.00619	0.05655	0.05583

Tabela 6.13: Wpływ parametru H na metryki ewaluacyjne modelu bazowego dla parametrów $X = 20$, $T = 75$ i $K = 12$.

Analiza ewaluacyjna uwypukla kluczowy dylemat kompromisu pomiędzy niedoreprezentowaniem strukturalnym a zjawiskiem nadmiernego wygładzenia. Zbyt krótka ścieżka ($H = 1$) wiąże węzły niszowe w ich bezpośrednim sąsiedztwie, zdominowanym przez najpopularniejsze huby. Z kolei nadmierne wydłużenie ścieżki ($H = 6$) doprowadza strukturę do kryzysu informacyjnego. Zawężenie tego parametru do wartości optymalnej $H = 4$ pozwala na uzyskanie najlepszych wyników.

Uwarunkowania rzadkich grafów silnie rezonują ze znanym w analizie sieci socjologicznych zjawiskiem małego świata (ang. *small-world phenomenon*) oraz ściśle z nim powiązaną teorią sześciu stopni oddalenia (ang. *six degrees of separation*) zapoczątkowaną przez eksperyment *S. Milgrama* [9].

Oznacza to, że przy długości ścieżki równej sześciu krokom, algorytm agregacji dysponuje polem recepcji o niemal globalnym zasięgu, łącząc węzeł źródłowy w zaledwie kilku skokach z praktycznie dowolnym innym obiektem w grafie. W rezultacie unikalne cechy profili zanikają wskutek zjawiska *oversmoothingu*, a zatarte reprezentacje degradują zdolności predykcyjne systemu.

Mechanikę tego kompromisu pomiędzy *Popularity Bias* a *oversmoothingiem* obrazuje Rysunek 8.5, przedstawiający dynamikę przestrzeni ukrytej dla metryki L_2 Norm. Wraz ze zwiększaniem parametru H , długość osadzeń dla grupy *Top 20%*

ulega systematycznemu wydłużeniu. Wynika to z faktu, że hity w rozszerzonym polu recepcji pełnią funkcję globalnych atraktorów – inkrementują swoją normę asymilując każdy najdrobniejszy sygnał, ponieważ z perspektywy optymalizacyjnej wchłanianie masy niekompatybilnych, powszechnych krawędzi działa na ich korzyść.

Odm inną dynamikę wykazuje grupa *Bottom 20%*, bazująca na rzadkich, unikalnych relacjach. Jeśli w wyniku głębokiej eksploracji ($H = 6$) przedmioty z tej grupy zostaną powiązane z dalekimi, niekompatybilnymi sąsiadami, ich hermetyczny sygnał ulega zagłuszeniu. W efekcie tracą one znaczenie w funkcji optymalizacyjnej, a ich reprezentacje ulegają skróceniu w konfrontacji z dominującymi węzłami.

Pozostałe dropouty

Dropout rate	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
0 (Baseline)	0.00764	0.04903	0.33142	0.18194
0.4	0.01420	0.05593	0.32573	0.18447
0.5	0.01776	0.05830	0.32332	0.18475
0.6	0.01940	0.06188	0.31957	0.18439
0.7	0.02198	0.06396	0.31441	0.18302
0.8	0.02128	0.06415	0.30854	0.18011
0.9	0.01341	0.05208	0.30397	0.17165
NDCG@20				
0 (Baseline)	0.00255	0.01916	0.23263	0.15381
0.4	0.00488	0.02309	0.23100	0.15577
0.5	0.00607	0.02433	0.23006	0.15611
0.6	0.00690	0.02609	0.22787	0.15605
0.7	0.00791	0.02741	0.22513	0.15520
0.8	0.00786	0.02806	0.21855	0.15200
0.9	0.00505	0.02227	0.20804	0.14277
Precision@20				
0 (Baseline)	0.00068	0.00619	0.05655	0.05583
0.4	0.00122	0.00718	0.05619	0.05670
0.5	0.00150	0.00746	0.05584	0.05678
0.6	0.00164	0.00786	0.05522	0.05665
0.7	0.00186	0.00811	0.05459	0.05626
0.8	0.00178	0.00805	0.05375	0.05552
0.9	0.00113	0.00648	0.05278	0.05291

Tabela 6.14: Wpływ siły *edge dropout* na metryki ewaluacyjne modelu bazowego.

W celu rzetelnej ewaluacji zaawansowanych mechanizmów próbkowania (*Pin-Sage*), konieczne jest zderzenie ich skuteczności z tradycyjnymi, mniej złożonymi metodami redukcji strukturalnej. W pierwszej kolejności badaniu poddano wpływ

Dropout rate	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
0 (Baseline)	0.00764	0.04903	0.33142	0.18194
0.02	0.00830	0.04876	0.32829	0.18057
0.04	0.00942	0.05024	0.32288	0.17880
0.06	0.01098	0.05197	0.31768	0.17732
0.08	0.01167	0.05151	0.31275	0.17592
0.1	0.01321	0.05229	0.30921	0.17456
NDCG@20				
0 (Baseline)	0.00255	0.01916	0.23263	0.15381
0.02	0.00294	0.01988	0.22717	0.15132
0.04	0.00339	0.02089	0.21972	0.14778
0.06	0.00404	0.02212	0.21247	0.14451
0.08	0.00457	0.02205	0.20617	0.14155
0.1	0.00523	0.02252	0.20112	0.13892
Precision@20				
0 (Baseline)	0.00068	0.00619	0.05655	0.05583
0.02	0.00073	0.00621	0.05610	0.05551
0.04	0.00086	0.00634	0.05531	0.05492
0.06	0.00098	0.00651	0.05455	0.05438
0.08	0.00106	0.00647	0.05378	0.05381
0.1	0.00117	0.00659	0.05325	0.05340

Tabela 6.15: Wpływ siły *node dropout* na metryki ewaluacyjne modelu bazowego.

losowego odrzucania krawędzi (*Edge Dropout*), który przetestowaliśmy dla sześciu różnych wartości ograniczających topologię grafu: $p \in \{0.4, 0.5, 0.6, 0.7, 0.8, 0.9\}$.

Analiza danych w Tabeli 6.14 ujawnia silny wpływ tej metody. Metryki predykcji ogólnej osiągają swoje maksimum dla wartości kompromisowej ($p = 0.5$). Z perspektywy zjawiska *Popularity Bias*, metoda wykazuje nieoczekiwanie wysoką skuteczność. Uszczuplenie macierzy sąsiedztwa na poziomie $p = 0.7$ pozwala na wyraźny awans w rankingu grupie *Bottom 20%*, której skuteczność blisko trzykrotnie przewyższa model bazowy. Jednak po przekroczeniu progu tolerancji ($p \geq 0.8$) model doświadcza spadku zdolności generalizacyjnych, co objawia się ponownym załamaniem predykcji w długim ogonie.

Zjawisko to znajduje odzwierciedlenie w analizie przestrzeni wektorowej (Rysunek 8.6). Zgromadzone dane ukazują bezpośrednią zależność między pogorszeniem predykcji modelu a zachowaniem osadzeń dla rosnącego parametru p : wartości L_2 Norm wszystkich węzłów ulegają rozrostowi, a wskaźnik *Cosine Drift* systematycznie rośnie. Wskazuje to, że zwiększenie długości wektorów przy niemal całkowitym ubytku krawędzi jest sztucznie wymuszana przez optymalizator w celu skompensowania krytycznych deficytów sygnału kolaboratywnego. Podwyższone wartości dryfu

kosinusowego dowodzą utraty stabilności układu. Dalsze zwiększanie współczynnika odrzucania ($p \geq 0.8$) usztywnia odizolowane wektory w niepożądanym obszarze przestrzeni, co ostatecznie pozbawia system spójnych relacji i wspomnianej wcześniej zdolności do generalizacji.

Identyczną dynamikę zaobserwowaliśmy podczas równoczesnej analizy usuwania węzłów (*Node Dropout*). Eksperymenty przeprowadziliśmy dla parametru p równej $\{0.02, 0.04, 0.06, 0.08, 0.1\}$. Jego wartości są znacznie mniejsze niż poprzednim przypadku, ponieważ jak jednoznacznie ukazuje Tabela 6.15, wygaszanie całych wierzchołków jest operacją znacznie bardziej destrukcyjną dla struktury grafu rzadkiego niż usuwanie pojedynczych krawędzi. Choć metoda ta skutecznie osłabia wpływ hubów, niemal podwajając skuteczność predykcji grupy *Bottom 20%*, odbywa się to kosztem natychmiastowej degradacji metryk globalnych całego systemu.

Zjawisko to potwierdza analiza przestrzeni ukrytej (Rysunek 8.7). Podobnie jak w wariancie *Edge Dropout*, agresywne uszczuplanie topologii wymusza wzrost norm L_2 w celu zrekompensowania utraconego sygnału, a także wywołuje destabilizację osadzeń mierzoną wysoką wartością dryfu.

Dowodzi to ostatecznie fundamentów kompromisu między badanymi metodami. Klasyczna stochastyczność z powodzeniem dekompresuje osadzenia przedmiotów popularnych, jednak ślepa losowość tłumi przy tym cenny sygnał kolaboratywny. Z kolei zbalansowane losowe spacery (*PinSage'a*) precyzyjnie chronią relacje niszowe przed zjawiskiem *Gradient Starvation*, lecz z inżynierskiego punktu widzenia okazuje się mechanizmem wysoce skomplikowanym strukturalnie i obliczeniowo.

6.4.5. Połączone podejścia

Nasze badania kończymy eksperymentując na mieszankach mechanizmów w celu sprawdzenia, czy po ich połączeniu da się zaobserwować efekt synergii czy raczej odwrotny trend. Pierwszą propozycją jest fuzja *Smoothed BPR* i *IPS* dla modelu bazowego. Trzema dalszymi są kombinacje modelu *FastLightGCN* (**FLGCN**) z powyższymi wymienionymi mechanizmami:

1. *FLGCN* + *IPS*,
2. *FLGCN* + *SBPR*,
3. *FLGCN* + *SBPR* + *IPS*.

Jako model bazowy dla *FLGCN* wybrano konfigurację [2048] oraz *batch size* = 2048, ponieważ oferowała najlepszy kompromis między jakością rekomendacji a czasem treningu.

C	α	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20					
Brak	Brak	0.00764	0.04903	0.33142	0.18194
20.0	1.0	0.04968	0.09637	0.14010	0.11724
20.0	0.5	0.03568	0.08988	0.20153	0.13770
20.0	0.25	0.03069	0.08285	0.23244	0.15102
5.0	0.25	0.02438	0.07786	0.27318	0.16730
NDCG@20					
Brak	Brak	0.00255	0.01916	0.23263	0.15381
20.0	1.0	0.02014	0.04839	0.08573	0.09284
20.0	0.5	0.01341	0.04308	0.13367	0.10617
20.0	0.25	0.01123	0.03860	0.15926	0.12057
5.0	0.25	0.00845	0.03428	0.19344	0.13906
Precision@20					
Brak	Brak	0.00068	0.00619	0.05655	0.05583
20.0	1.0	0.00421	0.01271	0.02137	0.03480
20.0	0.5	0.00306	0.01154	0.03292	0.04043
20.0	0.25	0.00257	0.01054	0.03886	0.04510
5.0	0.25	0.00203	0.00991	0.04646	0.05076

Tabela 6.16: Wpływ połączonych parametrów C oraz α na metryki ewaluacyjne modelu *LightGCN*.

LightGCN + *IPS* + *SBPR*

Analizując pierwszą z proponowanych hybryd, czyli połączenie mechanizmów *IPS* oraz *SBPR* zaaplikowane do klasycznego modelu *LightGCN*, zauważyliśmy niezwykle silny efekt synergii, który pozwala na radykalne sterowanie zjawiskiem *Popularity Bias*. Zestawienie wyników ewaluacyjnych wskazuje, że agresywna konfiguracja obu metod ($\alpha = 1.0$, $C = 20.0$) skutkuje bezprecedensowym tranferem skuteczności modelu. Co prawda globalne metryki trafności ulegają widocznemu pogorszeniu względem wariantu bazowego, jednak kryje się za tym całkowite przeniesienie uwagi sieci na elementy rzadsze. Wyniki w grupie Top 20% drastycznie się załamują, ale odbywa się to kosztem potężnego, wielokrotnego wzrostu skuteczności dla grupy Bottom 20% oraz silnego podbicia trafności dla decyli ze środka rozkładu (Middle 60%). Złagodzenie hiperparametrów hybrydy ($\alpha = 0.25$, $C = 5.0$) pozwala z kolei na znaczne odzyskanie globalnej jakości modelu, przy jednoczesnym zachowaniu bardzo wyraźnej poprawy dla elementów z długiego ogona.

To ekstremalne przesunięcie akcentów znajduje swoje bezpośrednie i bardzo czytelne odzwierciedlenie w dynamice wektorowej przestrzeni osadzeń, zaprezentowanej na Rysunku 8.8. Obserwując działanie łagodniejszej konfiguracji ($\alpha = 0.25$, $C = 20.0$) oraz systematyczne zwiększanie tych parametrów, można zauważyć wy-

rażne odseparowanie się najpopularniejszych przedmiotów od elementów ze środka stawki i nisz. Z perspektywy geometrii przestrzeni osadzeń zjawisko to można interpretować jako superpozycję – czyli fizyczne nakładanie się i sumowanie – dwóch ukierunkowanych sił. Obie metody niezależnie od siebie modyfikują gradienty w celu osłabienia hitów, a ich fuzja sprawia, że łączymy te wektory, uderzając w najczęściej wybierane przedmioty ze zwielokrotnioną siłą. W rezultacie połączone mechanizmy wspólnie, niezwykle agresywnie wypychają popularne obiekty z ich dominujących rejonów przestrzeni, robiąc miejsce dla rzadszych elementów z długiego ogona. Ten jednoznaczny trend wektorowy w pełni tłumaczy zaobserwowaną redystrybucję skuteczności, czyniąc dalszą, rozbitą na czynniki pierwsze analizę tego zjawiska zbędną.

FLGCN + *IPS*

Parametr <i>C</i>	Bottom 20%	Middle 60%	Top 20%	Główny
Recall@20				
Brak	0.00446	0.02614	0.28896	0.15172
100.0	0.00675	0.02936	0.27360	0.14920
200.0	0.00783	0.02953	0.27231	0.14906
400.0	0.00776	0.02963	0.27246	0.14902
NDCG@20				
Brak	0.00163	0.01067	0.18935	0.12345
100.0	0.00273	0.01260	0.17224	0.12090
200.0	0.00324	0.01261	0.17173	0.12068
400.0	0.00323	0.01256	0.17201	0.12062
Precision@20				
Brak	0.00043	0.00330	0.04704	0.04511
100.0	0.00065	0.00365	0.04402	0.04492
200.0	0.00075	0.00367	0.04387	0.04487
400.0	0.00075	0.00368	0.04389	0.04484

Tabela 6.17: Wpływ połączonych metod *FLGCN* ([2048] z *batch size* = 2048) i *IPS* (parametr *C*) na metryki ewaluacyjne.

Pierwszą z badanych kombinacji *FastLightGCN* jest jego fuzja z mechanizmem *IPS*. Zestawienie wyników ewaluacyjnych ujawnia bardzo korzystne i celowe przesunięcie balansu trafności. Choć przy optymalnej konfiguracji (np. dla $C = 200.0$) obserwujemy marginalny spadek globalnej trafności względem czystego modelu stochastycznego, wynika on wprost z ukierunkowanego osłabienia najpopularniejszych przedmiotów. W zamian model znacznie poprawia reprezentację długiego ogona, niemal podwajając trafność, a także zauważalnie podnosi wyniki dla obiektów ze środka rozkładu (Middle 60%). Należy jednak zaznaczyć, że systematyczne zwiększanie rygorystyczności parametru wagi *IPS* (testowane kolejno dla $C \geq 200.0$) stosunkowo

szybko przestaje przynosić proporcjonalne korzyści. Skrajne wartości parametru wykazują zatrzymanie poprawy wyników, co wskazuje na szybkie osiągnięcie punktu nasycenia dla potencjału tej metody.

Z perspektywy geometrii przestrzeni osadzeń, zaprezentowanej na Rysunku 8.9, zachowanie tej hybrydy jest bardzo zbliżone do zjawisk zaobserwowanych wcześniej przy analizie *IPS* dla klasycznego modelu *LightGCN*. Odwrócenie ról na wykresach w stosunku do *baseline'u* jest wyraźne, jednak zjawisko to ogranicza się wyłącznie do metryki L_2 Norm. Zgodnie z naszymi wcześniejszymi wnioskami, mechanizm ten przymusowo zwiększa wektory niszy – ich długość dynamicznie rośnie, niemal całkowicie zacierając dotychczasową przepaść i zrównując się z hitami (osiągając dla $C = 200.0$ wspólny poziom w granicach $8.56 - 8.85$).

Z kolei w przypadku metryki *Cosine Drift* zauważamy to samo zjawisko wyraźnego odwrócenia pozycji dryfu hitów i niszy, które zdiagnozowaliśmy w analizie *IPS* dla *baseline'u*. W czystym *FastLightGCN* to obiekty z ogona dryfowały najsilniej, natomiast po fuzji z *IPS* grupy te całkowicie zamieniają się miejscami na wykresie. Poziom dryfu kosinusowego wcale się jednak nie zmniejsza, w przeciwieństwie do fuzji na klasycznym modelu. Wynika to z faktu, że w architekturze stochastycznej aktualizujemy jedynie wierzchołki z pierwszej warstwy próbkowanego grafu. Przedmioty niszowe mają w nim z natury bardzo mało krawędzi, przez co ich obecność w sampelowanym sąsiedztwie jest rzadka i wysoce nieprzewidywalna, co wprost podtrzymuje wysoki poziom ich dryfu.

FLGCN + SBPR

Parametr α	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20				
Brak	0.00446	0.02614	0.28896	0.15172
0.25	0.00517	0.02724	0.28981	0.15301
0.5	0.00545	0.02935	0.29150	0.15415
0.75	0.00632	0.02986	0.28948	0.15415
1.0	0.00649	0.03006	0.28758	0.15315
1.25	0.00660	0.02996	0.28116	0.15054
NDCG@20				
Brak	0.00163	0.01067	0.18935	0.12345
0.25	0.00180	0.01113	0.19099	0.12516
0.5	0.00199	0.01185	0.19257	0.12632
0.75	0.00233	0.01235	0.19109	0.12598
1.0	0.00238	0.01249	0.18893	0.12410
1.25	0.00245	0.01256	0.18350	0.12146
Precision@20				
Brak	0.00043	0.00330	0.04704	0.04511
0.25	0.00047	0.00347	0.04780	0.04604
0.5	0.00052	0.00370	0.04832	0.04651
0.75	0.00060	0.00382	0.04816	0.04661
1.0	0.00064	0.00381	0.04772	0.04629
1.25	0.00063	0.00384	0.04664	0.04537

Tabela 6.18: Wpływ połączonych metod *FLGCN* ([2048] z *batch size* = 2048) i *SBPR* (parametr α) na metryki ewaluacyjne.

Drugą analizowaną hybrydą *FastLightGCN* jest jego połączenie z mechanizmem *Smoothed BPR* (*SBPR*). Zestawienie wyników ewaluacyjnych również ukazuje w tym przypadku zadawalający efekt synergii. O ile *IPS* poprawiał pozycję niszy głównie kosztem popularnych przedmiotów, o tyle umiarkowane warianty *SBPR* (np. konfiguracje dla $\alpha \in [0.5, 1.0]$) nie tylko zauważalnie podnoszą trafność dla obiektów rzadkich i ze środka stawki, ale jednocześnie poprawiają globalną jakość rekomendacji. Przykładowo, wariant z $\alpha = 0.75$ zauważalnie przewyższa czysty model stochastyczny pod kątem ogólnej trafności, udowadniając, że wygładzanie dystrybucji negatywów prowadzi do znacznie bardziej równego uczenia przestrzeni. Dopiero najbardziej agresywna z badanych wartości ($\alpha = 1.25$) wymusza większe osłabianie hitów na rzecz maksymalizacji wyników niszy.

Na wykresach (Rysunek 8.10) widać, z czego wynika sukces tej metody. Metryka L_2 Norm obrazuje, w jaki sposób mechanizm ten zarządza siłą wektorów. Przy niskiej wartości parametru ($\alpha = 0.25$) zachowana zostaje naturalna hierarchia, w której to hity posiadają najdłuższe osadzenia. Zwiększenie tego parametru do $\alpha = 1.0$ skut-

kuje wyrównaniem długości wektorów – reprezentacje dla wszystkich grup stabilizują się na wspólnym poziomie. Z kolei ekstremalne ustawienie ($\alpha = 1.25$) prowadzi do fizycznego odwrócenia ról, gdzie wektory długiego ogona stają się dłuższe od osadzeń hitów.

Na wykresach *Cosine Drift* widzimy natomiast, że mechanizm *SBPR* w środowisku stochastycznym zachowuje się bardzo podobnie jak w modelu bazowym *LightGCN*. Wraz ze wzrostem parametru α , mechanizm w sposób stabilny i przewidywalny osłabia dryf hitów wobec innych grup.

FLGCN + *SBPR* + *IPS*

C	α	Bottom 20%	Middle 60%	Top 20%	Globalne
Recall@20					
Brak	Brak	0.00446	0.02614	0.28896	0.15172
100.0	0.75	0.01022	0.03591	0.27160	0.15017
200.0	0.75	0.01162	0.03650	0.26978	0.14998
400.0	0.75	0.01165	0.03641	0.26982	0.14997
200.0	1.25	0.01384	0.03685	0.25813	0.14489
NDCG@20					
Brak	Brak	0.00163	0.01067	0.18935	0.12345
100.0	0.75	0.00410	0.01529	0.17421	0.12010
200.0	0.75	0.00469	0.01560	0.17320	0.11964
400.0	0.75	0.00473	0.01546	0.17302	0.11958
200.0	1.25	0.00576	0.01585	0.16344	0.11448
Precision@20					
Brak	Brak	0.00043	0.00330	0.04704	0.04511
100.0	0.75	0.00099	0.00445	0.04491	0.04538
200.0	0.75	0.00111	0.00454	0.04468	0.04530
400.0	0.75	0.00111	0.00453	0.04469	0.04529
200.0	1.25	0.00127	0.00460	0.04295	0.04377

Tabela 6.19: Wpływ połączonych metod *IPS* (parametr C) oraz *SBPR* (parametr α) na metryki ewaluacyjne dla modelu *FLGCN* ([2048] z *batch size* = 2048).

Badania kończymy analizą najbardziej zaawansowanej hybrydy: *FastLightGCN* z mechanizmami *IPS* oraz *SBPR*. Eksperyment ten przeprowadzono przy użyciu optymalnego dla tego modelu parametru wygładzania ($\alpha = 0.75$), systematycznie zwiększając próg odcięcia wag C (od 100.0 do 400.0). Zestawienie wyników ewaluacyjnych udowadnia, że jest to niezwykle skuteczna konfiguracja. Połączenie obu metod pozwala na imponujące, niemal trzykrotne zwiększenie trafności dla rzadkich przedmiotów oraz zauważalny wzrost wyników dla Middle 60%, przy zaledwie minimalnym ubytku ogólnej jakości całego modelu. Zauważamy tu jednak wyraźny efekt

nasycenia – przeskok z parametru $C = 200.0$ na $C = 400.0$ nie przynosi już niemal żadnych zmian w metrykach, wyznaczając optymalną granicę użyteczności tej metody. Weryfikacja dodatkowego, ekstremalnego wariantu ($\alpha = 1.25, C = 200.0$) dowodzi z kolei, że godząc się na wyraźniejszy spadek globalnej trafności i mocniejsze osłabienie hitów, model potrafi wygenerować historyczny, ponad trzykrotny wzrost skuteczności rekomendacji dla długiego ogona.

Na wykresach (Rysunek 8.11) widać doskonale, z czego wynika sukces tego połączenia. W przypadku metryki $L_2 Norm$ mechanizmy te generują silne, postępujące rozwarstwienie grup, tworząc zupełnie nową, odwrotną hierarchię. Z jednej strony *SBPR* skutecznie blokuje przyrost długości wektorów dla hitów, z drugiej zaś *IPS* konsekwentnie wydłuża osadzenia niszy. W efekcie, wraz ze zwiększaniem progu odcięcia do $C = 400.0$, rzadsze przedmiotów (Middle 60% i Bottom 20%) systematycznie oddalają się od osadzeń grupy Top 20%.

Zupełnie inną dynamikę widać na wykresach *Cosine Drift*, gdzie zjawiska te można zinterpretować jako modelową superpozycję sił. Dokonując wizualnego nałożenia na siebie wykresów z dwóch poprzednich eksperymentów – wariantu *FastLightGCN + SBPR* (dla $\alpha = 0.75$) oraz fuzji z *IPS* – wyraźnie widać, że wypadkowy przebieg wektorów dla pełnej hybrydy jest niemal dokładną sumą ich oddziaływań.

6.5. Podsumowanie eksperymentów

Przeprowadziliśmy trzy typy eksperymentów. Pierwszym były modyfikacje funkcji straty *BPR* na poziomie zmiany rozkładu prawdopodobieństwa dla negatywnych przedmiotów oraz ważenia pozytywnych przedmiotów odwrotnie proporcjonalnie do ich popularności. Drugim rodzajem były metody próbkowania i regularyzacji struktury grafu: *FastGCN* dostosowany do potrzeb rzadkich grafów, aproksymujący działanie warstwy konwolucyjnej, zaawansowane próbkowanie grafów losowymi space-rami *PinSage’a* oraz proste *edge* i *node* dropouty. Na koniec testowaliśmy hybrydy powyższych mechanizmów. We wszystkich analizowanych metodach kluczowe było znalezienie kompromisu pomiędzy poprawą jakości rekomendacji dla przedmiotów z długiego ogona a kontrolowanym spadkiem skuteczności dla hitów i metryk globalnych. Podsumowując powyższe eksperymenty, zauważyliśmy następujące obserwacje:

- *Smoothed BPR* oraz *IPS* skutecznie łagodzą zjawisko *Popularity Bias*. W obu przypadkach wzrost siły regularyzacji poprawia wyniki dla przedmiotów z długiego ogona, lecz jednocześnie prowadzi do kontrolowanego spadku metryk globalnych oraz osłabienia dominacji grupy *Top 20%*,
- w modelu *FastLightGCN* kluczowe znaczenie ma jakość aproksymacji warstw propagacji:

- głębsze modele są użyteczne tylko wtedy, gdy szerokość próbkowanych warstw jest dostatecznie duża; przy zbyt wąskim próbkowaniu błąd aproksymacji narasta wraz z głębokością i degradowuje jakość rekomendacji,
 - narzucanie globalnej unikalności próbkowanych węzłów między warstwami okazało się niekorzystne, ponieważ ogranicza złożoność ścieżek propagacji sygnału kolaboratywnego,
 - parametr *batch size*, będący zarazem rozmiarem warstwy wejściowej, powinien pozostawać odpowiednio mały względem szerokości próbkowanej pierwszej warstwy, aby poprawiać jakość estymacji oraz zwiększać częstość aktualizacji gradientowych,
 - wygładzanie rozkładu próbkowania (*SIS*) stabilizuje uczenie względem próbkowania silnie zależnego od stopnia węzła, jednak zbyt agresywne wygładzanie nie prowadzi do poprawy metryk,
- próbkowanie grafu inspirowane modelem *PinSage* poprawiało wyniki w grupach niszowych i pośrednich, a przy odpowiednim doborze parametrów pozwalało także utrzymać konkurencyjne wyniki globalne; w szczególności:
 - przebudowa grafu może być wykonywana relatywnie rzadko, co pozwala ograniczyć koszt obliczeniowy bez istotnej utraty jakości,
 - rozmiar sąsiedztwa powinien być umiarkowany, aby odfiltrować nadmiarowe krawędzie wokół popularnych węzłów,
 - liczba losowych ścieżek musi być wystarczająco duża, aby zapewnić stabilne i mało zaszumione sąsiedztwo,
 - długość ścieżek nie powinna być zbyt duża, ponieważ prowadzi to do zjawiska *oversmoothingu*,
 - *edge dropout* okazał się jedną z najbardziej praktycznych metod regularyzacji struktury grafu: poprawiał wyniki dla grup *Bottom 20%* i *Middle 60%*, osłabiał dominację hitów, a przy umiarkowanych wartościach parametru pozwalał również uzyskać bardzo dobre metryki globalne,
 - *node dropout* działał słabiej niż *edge dropout*, co wynika z jego bardziej destrukcyjnego wpływu na strukturę rzadkiego grafu; poprawa dla grup mniej popularnych była ograniczona i okupiona większą degradacją jakości globalnej,
 - podejścia hybrydowe wykazywały efekt synergii. Szczególnie korzystne okazało się łączenie metod strukturalnych z modyfikacjami funkcji straty, przy czym w przypadku jednoczesnego stosowania *SBPR* oraz *IPS* konieczne było zachowanie umiarkowanych wartości parametrów, aby nie doprowadzić do nadmiernego spadku metryk globalnych.

Rozdział 7.

Podsumowanie

W niniejszej pracy skupiliśmy się na problemie *Popularity Bias* w systemach rekomendujących opartych na grafowych sieciach neuronowych. Założyliśmy, że struktura danych oraz sposób uczenia modeli prowadzą do faworyzowania przedmiotów popularnych kosztem elementów należących do długiego ogona. Celem pracy było zbadanie, czy możliwe jest ograniczenie tego zjawiska poprzez modyfikację funkcji straty oraz struktury grafu.


W pracy opisaliśmy architekturę *LightGCN* i wykorzystaliśmy ją jako model bazowy do przeprowadzonych eksperymentów. Przetestowaliśmy metody należące do kategorii *in-processing*, w tym *Smoothed BPR*, *Inverse Propensity Scoring*, autorski model *FastLightGCN*, próbkowanie inspirowane *PinSage'em* oraz techniki *edge* i *node dropout*. Zbadaliśmy również połączenia wybranych metod w celu sprawdzenia, czy możliwe jest uzyskanie efektu synergii.

Przeprowadzone eksperymenty pokazały, że ograniczanie *Popularity Bias* jest możliwe, ale wiąże się z koniecznością zachowania kompromisu pomiędzy poprawą wyników dla przedmiotów niszowych a utrzymaniem jakości globalnej. Najlepsze efekty uzyskaliśmy dla odpowiednio dobranych modyfikacji funkcji straty, próbkowania inspirowanego *PinSage'em*, *edge dropoutu* oraz metod hybrydowych. Jednocześnie wyniki potwierdziły, że problem ten jest złożony i nie może zostać rozwiązany przez jeden uniwersalny mechanizm.


W przyszłości warto rozszerzyć badania o inne zbiory danych. Interesującym kierunkiem byłoby również dokładniejsze zbadanie mechanizmu losowania przykładów pozytywnych i negatywnych w funkcji *BPR*, poprzez odejście od standardowego schematu na rzecz kontrolowanego doboru par pomiędzy grupami popularności, na przykład: nisz–hit, nisz–*Middle*, hit–hit czy *Middle*–hit. Takie podejście mogłoby umożliwić bardziej precyzyjne sterowanie relacjami rankingowymi między przedmiotami oraz świadome osłabianie dominacji elementów popularnych.

Rozdział 8.


Dodatek



Rysunek 8.1: Przedstawienie zjawiska *overfittingu* dla wartości parametru $X = 100$




(a) Skrajne głębokości i szerokości próbkowanego grafu




(b) Różne wartości rozkładu prawdopodobieństwa *SIS*


Rysunek 8.2: Wykresy funkcji straty modelu *FastLightGCN*




(a) L_2 Norm dla $K = 8$



(b) *Cosine Drift* dla $K = 8$





(c) L_2 Norm dla $K = 20$





(d) *Cosine Drift* dla $K = 20$





Rysunek 8.3: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego (*Cosine Drift*) wektorów przedmiotów w grupach popularności dla różnych wartości parametru K dla próbkowania grafu *PinSage*

(a) L_2 Norm dla $T = 25$ (b) L_2 Norm dla $T = 125$





Rysunek 8.4: Porównanie dynamiki normy L_2 wektorów przedmiotów w grupach popularności dla różnych wartości parametru T dla próbkowania grafu *PinSage*

(a) L_2 Norm dla $H = 1$ (b) L_2 Norm dla $H = 6$







Rysunek 8.5: Porównanie dynamiki normy L_2 wektorów przedmiotów w grupach popularności dla różnych wartości parametru H dla próbkowania grafu *PinSage*

(a) L_2 Norm dla $p = 0.4$ (b) $Cosine$ Drift dla $p = 0.4$ (c) L_2 Norm dla $p = 0.9$ (d) $Cosine$ Drift dla $p = 0.9$







Rysunek 8.6: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego ($Cosine$ Drift) wektorów przedmiotów w grupach popularności dla różnych wartości parametru p dla $Edge$ Dropout

(a) L_2 Norm dla $p = 0.02$ (b) *Cosine Drift* dla $p = 0.02$ (c) L_2 Norm dla $p = 0.1$ (d) *Cosine Drift* dla $p = 0.1$







Rysunek 8.7: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego (*Cosine Drift*) wektorów przedmiotów w grupach popularności dla różnych wartości parametru p dla *Node Dropout*

(a) L_2 Norm dla $\alpha = 0.25$ i $C = 20$ (b) $Cosine$ Drift dla $\alpha = 0.25$ i $C = 20$ (c) L_2 Norm dla $\alpha = 0.5$ i $C = 20$ (d) $Cosine$ Drift dla $\alpha = 0.5$ i $C = 20$ (e) L_2 Norm dla $\alpha = 1.0$ i $C = 20$ (f) $Cosine$ Drift dla $\alpha = 1.0$ i $C = 20$







Rysunek 8.8: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego ($Cosine$ Drift) wektorów przedmiotów w grupach popularności dla wybranych konfiguracji połączonych metod $SBPR$ oraz IPS .

(a) L_2 Norm dla modelu bazowego(b) *Cosine Drift* dla modelu bazowego(c) L_2 Norm dla $C = 100$ (d) *Cosine Drift* dla $C = 100$ (e) L_2 Norm dla $C = 200$ (f) *Cosine Drift* dla $C = 200$

Rysunek 8.9: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego (*Cosine Drift*) wektorów przedmiotów w grupach popularności dla modelu bazowego *FLGCN* ([2048] z *batch size* = 2048) oraz wariantów z metodą *IPS* dla różnych wartości parametru C .

(a) $L_2 Norm$ dla $\alpha = 0.25$ (b) $Cosine Drift$ dla $\alpha = 0.25$ (c) $L_2 Norm$ dla $\alpha = 0.75$ (d) $Cosine Drift$ dla $\alpha = 0.75$ (e) $L_2 Norm$ dla $\alpha = 1.25$ (f) $Cosine Drift$ dla $\alpha = 1.25$

Rysunek 8.10: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego ($Cosine Drift$) wektorów przedmiotów w grupach popularności dla modelu hybrydowego $FLGCN + SBPR$ dla różnych wartości parametru α .

(a) $L_2 Norm$ dla $\alpha = 0.75$ i $C = 100.0$ (b) $Cosine Drift$ dla $\alpha = 0.75$ i $C = 100.0$ (c) $L_2 Norm$ dla $\alpha = 0.75$ i $C = 200.0$ (d) $Cosine Drift$ dla $\alpha = 0.75$ i $C = 200.0$ (e) $L_2 Norm$ dla $\alpha = 0.75$ i $C = 400.0$ (f) $Cosine Drift$ dla $\alpha = 0.75$ i $C = 400.0$

Rysunek 8.11: Porównanie dynamiki normy L_2 oraz dryfu kosinusowego ($Cosine Drift$) wektorów przedmiotów w grupach popularności dla modelu hybrydowego $FLGCN + IPS + SBPR$ przy stałej wartości parametru $\alpha = 0.75$ oraz różnych konfiguracjach parametru limitu C .

Bibliografia

- [1] Francesco Casalegno. Recommender systems: A complete guide to machine learning models. <https://medium.com/data-science/recommender-systems-a-complete-guide-to-machine-learning-models-96d3f94ea748>, 2020.
- [2] Jie Chen, Tengfei Ma, and Cao Xiao. Fastgcn: Fast learning with graph convolutional networks via importance sampling. In *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*. OpenReview.net, 2018. URL: <https://openreview.net/forum?id=rytstxWAW>.
- [3] Paolo Cremonesi, Franca Garzotto, Roberto Pagano, and Massimo Quadrana. Recommending without short head. In *Companion Proceedings of the 23rd International Conference on World Wide Web*, pages 245–246. ACM, 2014. doi:10.1145/2567948.2577286.
- [4] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. Lightgcn: Simplifying and powering graph convolution network for recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR 2020, Virtual Event, China, July 25-30, 2020*, pages 639–648. ACM, 2020. doi:10.1145/3397271.3401063.
- [5] Wei Ju, Siyu Yi, Yifan Wang, Zhiping Xiao, Zhengyang Zhou, Liang Chen, Hao Wang, and Ming Zhang. A survey of graph neural networks in real world: Imbalance, noise, privacy and ood challenges. *CoRR*, abs/2403.04468, 2024. arXiv:2403.04468, doi:10.48550/arXiv.2403.04468.
- [6] Wang-Cheng Kang and Julian McAuley. Self-attentive sequential recommendation. In *2018 IEEE International Conference on Data Mining (ICDM)*, pages 197–206. IEEE, 2018. URL: <https://arxiv.org/abs/1808.09781>, doi:10.1109/ICDM.2018.00035.
- [7] Anastasiia Klimashevskaya, Dietmar Jannach, Mehdi Elahi, and Christoph Trattner. A survey on popularity bias in recommender systems. *arXiv pre-*

- print arXiv:2308.01118*, 2023. URL: <https://arxiv.org/abs/2308.01118>, doi:10.48550/arXiv.2308.01118.
- [8] Venkata Harshit Koneru, Xenija Neufeld, Sebastian Loth, and Andreas Grün. Enhancing recommendation quality of the sasrec model by mitigating popularity bias. In *Proceedings of the 18th ACM Conference on Recommender Systems*, pages 780–782. ACM, 2024. doi:10.1145/3640457.3688044.
- [9] Stanley Milgram. The small world problem. *Psychology Today*, 1(1):60–67, 1967. URL: <https://snap.stanford.edu/class/cs224w-readings/milgram67smallworld.pdf>.
- [10] Francesco Ricci, Lior Rokach, and Bracha Shapira, editors. *Recommender Systems Handbook*. Springer, New York, 2022. doi:10.1007/978-1-0716-2197-4.
- [11] Xiang Wang, Xiangnan He, Meng Wang, Fuli Feng, and Tat-Seng Chua. Neural graph collaborative filtering. In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR 2019, Paris, France, July 21-25, 2019*, pages 165–174. ACM, 2019. doi:10.1145/3331184.3331267.
- [12] Rex Ying, Ruining He, Kaifeng Chen, Pong Eksombatchai, William L. Hamilton, and Jure Leskovec. Graph convolutional neural networks for web-scale recommender systems. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD 2018, London, UK, August 19-23, 2018*, pages 974–983. ACM, 2018. doi:10.1145/3219819.3219890.
- [13] Ziwei Zhu, Yun He, Xing Zhao, Yin Zhang, Jianling Wang, and James Caverlee. Popularity-opportunity bias in collaborative filtering. In *Proceedings of the Fourteenth ACM International Conference on Web Search and Data Mining*, pages 85–93. ACM, 2021. doi:10.1145/3437963.3441820.
- [14] Difan Zou, Ziniu Hu, Yewen Wang, Song Jiang, Yizhou Sun, and Quanquan Gu. Layer-dependent importance sampling for training deep and large graph convolutional networks. *CoRR*, abs/1911.07323, 2019. URL: <https://arxiv.org/abs/1911.07323>, arXiv:1911.07323.